# Analyse statique de logiciel système par typage statique fort

Application au noyau Linux

Étienne Millon

14 août 2012

ABSTRACT

Abstract ici.

#### ACKNOWLEDGEMENTS

Remerciements

Cassedédi

## TABLE DES MATIÈRES

Ta	Table des matières					
1	Intı	oducti	on	1		
Ι	Mé	thodes	s formelles pour la sécurité	3		
2	Sys	tèmes (	d'exploitation	5		
	2.1	Rôle d	'un système d'exploitation	. 5		
	2.2	Archit	ecture Intel	. 6		
		2.2.1	Assembleur	. 6		
		2.2.2	Fonctions et conventions d'appel	. 8		
		2.2.3	Tâches, niveaux de privilèges	. 9		
		2.2.4	Mémoire virtuelle	. 10		
	2.3	Cas de	e Linux	. 10		
		2.3.1	Appels système			
	2.4	Sécuri	té des appels système	. 13		
3	Тур	age		17		
	3.1	Préser	ntation et but	. 17		
	3.2	Taxon	omie	. 17		
		3.2.1	Dynamique, statique, mixte	. 17		
		3.2.2	Fort, faible, sound	. 20		
		3.2.3	Polymorphisme	. 21		
		3.2.4	Expressivité, garanties, types dépendants	. 23		
	3.3	Exem	ples	. 23		
		3.3.1	Faible dynamique : Perl			
		3.3.2	Faible statique : C			
		3.3.3	Fort dynamique: Python			
		3.3.4	Fort statique : OCaml			
		3.3.5	Fort statique à effets typés : Haskell			
		3.3.6	Theorem prover: Coq	. 23		
4	Éta	t de l'a	rt	25		
II	Тур	oage st	tatique de langages impératifs	27		
5	Sén	nantiqu	ie d'un langage impératif	29		
	5.1	Synta	xe	. 29		

5.2. Sémantique       29         5.2.1 Graphe de flot de contrôle       31         5.2.2 État mémoire       32         5.2.3 Jugements       32         5.2.4 Sémantique des left-values       33         5.2.5 Sémantique des expressions       33         5.2.6 Sémantique des conditions       34         5.2.7 Sémantique des conditions       34         6 Sémantique statique       37         6.1. Regles de typage       37         6.1.2 Schémas de type       37         6.1.2 Schémas de type       37         6.1.3 Environnements de typage       39         6.1.4 Jugements de typage       39         6.1.5 Programme       40         6.1.6 Flot de contrôle       40         6.1.7 Left values       40         6.1.8 Expressions       41         6.1.9 Fonctions       42         6.1.10 Instructions       42         6.2.1 Imitations       43         6.2.2 Limitations       43         6.2.3 Fonctions de copinteurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chânes C       47         8.1 But       47	TA	BLE	DES M	ATIÈRES	vii				
5.2.2       État mémoire       32         5.2.3       Jugements       32         5.2.4       Sémantique des left-values       33         5.2.5       Sémantique des instructions       34         5.2.6       Sémantique des conditions       34         6.2.7       Sémantique des conditions       34         6 Sémantique statique       37         6.1.1       Types       37         6.1.2       Schémas de type       37         6.1.2       Schémas de type       37         6.1.1       Types       37         6.1.2       Schémas de type       39         6.1.1       Fuvironnements de typage       39         6.1.5       Programme       40         6.1.5       Programme       40         6.1.6       Flot de contrôle       40         6.1.7       Left values       40         6.1.8       Expressions       41         6.1.9       Fonctions       42         6.1.10       Instructions       42         6.2       Limitations       43         6.2.1       Programmes non typables       43         6.2.1       Programmes non typables       43 </td <td></td> <td>5.2</td> <td>Séman</td> <td>atique</td> <td>29</td>		5.2	Séman	atique	29				
5.2.3       Jugements       32         5.2.4       Sémantique des left-values       33         5.2.5       Sémantique des instructions       34         5.2.7       Sémantique des conditions       34         6.2.7       Sémantique des conditions       34         6.1       Règles de typage       37         6.1.1       Types       37         6.1.2       Schémas de type       37         6.1.3       Environnements de typage       39         6.1.4       Jugements de typage       39         6.1.5       Programme       40         6.1.6       Flot de contrôle       40         6.1.7       Left values       40         6.1.8       Expressions       41         6.1.9       Fonctions       42         6.1.10       Instructions       42         6.1.10       Instructions       42         6.2.1       Irogrammes non typables       43         6.2.2       Incohérences       43         7       Analyse de provenance des pointeurs       45         7.1       Éditions et ajouts       45         7.2       Propriété d'isolation mémoire       45         8.3 <td></td> <td></td> <td>5.2.1</td> <td>Graphe de flot de contrôle</td> <td>31</td>			5.2.1	Graphe de flot de contrôle	31				
5.2.4       Sémantique des left-values       33         5.2.5       Sémantique des expressions       34         5.2.6       Sémantique des instructions       34         5.2.7       Sémantique des conditions       34         6       Sémantique statique       37         6.1       Règles de typage       37         6.1.1       Types       37         6.1.2       Schémas de type       37         6.1.3       Environnements de typage       39         6.1.4       Jugements de typage       39         6.1.5       Programme       40         6.1.6       Flot de contrôle       40         6.1.7       Left values       40         6.1.8       Expressions       41         6.1.9       Fonctions       42         6.1.10       Instructions       42         6.2       Limitations       42         6.2.1       Programmes non typables       43         6.2.2       Incohérences       43         7       Analyse de provenance des pointeurs       45         7.1       Éditions et ajouts       45         7.2       Propriété d'isolation mémoire       45         8 <td></td> <td></td> <td>5.2.2</td> <td>État mémoire</td> <td>32</td>			5.2.2	État mémoire	32				
5.2.5       Sémantique des expressions       33         5.2.6       Sémantique des instructions       34         5.2.7       Sémantique des conditions       34         6       Sémantique statique       37         6.1       Règles de typage       37         6.1.1       Types       37         6.1.2       Schémas de type       37         6.1.3       Environnements de typage       39         6.1.4       Jugements de typage       39         6.1.5       Programme       40         6.1.6       Flot de contrôle       40         6.1.7       Left values       40         6.1.8       Expressions       41         6.1.9       Fonctions       42         6.1.10       Instructions       42         6.2.1       Programmes non typables       43         6.2.1       Programmes non typables       43         6.2.2       Incohérences       43         7       Analyse de provenance des pointeurs       45         7.1       Éditions et ajouts       45         7.2       Propriété d'isolation mémoire       45         8       Analyse de terminaison des chaînes C       47			5.2.3	Jugements	32				
5.2.6       Sémantique des conditions       34         5.2.7       Sémantique des conditions       34         6       Sémantique statique       37         6.1       Règles de typage       37         6.1.1       Types       37         6.1.2       Schémas de type       37         6.1.3       Environnements de typage       39         6.1.4       Jugements de typage       39         6.1.5       Programme       40         6.1.6       Flot de contrôle       40         6.1.7       Left values       40         6.1.8       Expressions       41         6.1.9       Fonctions       42         6.1.0       Instructions       42         6.2       Limitations       43         6.2.1       Programmes non typables       43         6.2.2       Incohérences       43         7       Analyse de provenance des pointeurs       45         7.1       Éditions et ajouts       45         7.2       Propriété d'isolation mémoire       45         8       Analyse de terminaison des chaînes C       47         8.1       But       47         8.2       Approch			5.2.4	Sémantique des left-values	33				
5.2.7 Sémantique des conditions       34         6 Sémantique statique       37         6.1 Règles de typage       37         6.1.2 Schémas de type       37         6.1.3 Environnements de typage       39         6.1.4 Jugements de typage       39         6.1.5 Programme       40         6.1.6 Flot de contrôle       40         6.1.7 Left values       40         6.1.8 Expressions       41         6.1.9 Fonctions       42         6.1.10 Instructions       42         6.2 Limitations       43         6.2.1 Programmes non typables       43         6.2.2 Incohérences       43         7 Analyse de provenance des pointeurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3.1 Fonctions de concaténation       49         8.3.2 Fonctions de comparaison       49         8.3.3 Fonctions de recherche       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats			5.2.5	Sémantique des expressions	33				
6 Sémantique statique 6.1 Règles de typage 37 6.1.1 Types 37 6.1.2 Schémas de type 37 6.1.3 Environnements de typage 39 6.1.4 Jugements de typage 39 6.1.5 Programme 40 6.1.6 Flot de contrôle 40 6.1.7 Left values 40 6.1.8 Expressions 41 6.1.9 Fonctions 42 6.1.10 Instructions 42 6.2 Limitations 42 6.2.1 Programmes non typables 43 6.2.2 Incohérences 43 7 Analyse de provenance des pointeurs 7.1 Éditions et ajouts 7.2 Propriété d'isolation mémoire 45 8 Analyse de terminaison des chaînes C 8.1 But 8.2 Approche 8.3 Annotation de string.h 8.3.1 Fonctions de coopie 8.3.2 Fonctions de concaténation 8.3.3 Fonctions de comparaison 9.8.3.4 Fonctions de comparaison 9.8.3.5 Fonctions de recherche 9.8.3.6 Résultats 51 III Expérimentation 53			5.2.6	Sémantique des instructions	34				
6.1 Règles de typage       37         6.1.1 Types       37         6.1.2 Schémas de type       37         6.1.3 Environnements de typage       39         6.1.4 Jugements de typage       39         6.1.5 Programme       40         6.1.6 Flot de contrôle       40         6.1.7 Left values       40         6.1.8 Expressions       41         6.1.9 Fonctions       42         6.1.10 Instructions       42         6.2.1 Programmes non typables       43         6.2.2 Imitations       43         6.2.2 Incohérences       43         7 Analyse de provenance des pointeurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.5 Extensions au système de types       51         8.6 Résultats       51			5.2.7	Sémantique des conditions	34				
6.1 Règles de typage       37         6.1.1 Types       37         6.1.2 Schémas de type       37         6.1.3 Environnements de typage       39         6.1.4 Jugements de typage       39         6.1.5 Programme       40         6.1.6 Flot de contrôle       40         6.1.7 Left values       40         6.1.8 Expressions       41         6.1.9 Fonctions       42         6.1.10 Instructions       42         6.2.1 Programmes non typables       43         6.2.2 Imitations       43         6.2.2 Incohérences       43         7 Analyse de provenance des pointeurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.5 Extensions au système de types       51         8.6 Résultats       51	ß	Sám	antian	a stationa	27				
6.1.1 Types       37         6.1.2 Schémas de type       37         6.1.3 Environnements de typage       39         6.1.4 Jugements de typage       39         6.1.5 Programme       40         6.1.6 Flot de contrôle       40         6.1.7 Left values       40         6.1.8 Expressions       41         6.1.9 Fonctions       42         6.1.10 Instructions       42         6.2 Limitations       43         6.2.1 Programmes non typables       43         6.2.2 Incohérences       43         7 Analyse de provenance des pointeurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string.h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.4 Typage des primitives       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51	U		_	<del>-</del>					
6.1.2       Schémas de type       37         6.1.3       Environnements de typage       39         6.1.4       Jugements de typage       39         6.1.5       Programme       40         6.1.6       Flot de contrôle       40         6.1.7       Left values       40         6.1.8       Expressions       41         6.1.9       Fonctions       42         6.1.10       Instructions       42         6.2       Limitations       43         6.2.1       Programmes non typables       43         6.2.2       Incohérences       43         7       Analyse de provenance des pointeurs       45         7.1       Éditions et ajouts       45         7.2       Propriété d'isolation mémoire       45         8       Analyse de terminaison des chaînes C       47         8.1       But       47         8.2       Approche       48         8.3       Annotation de string.h       49         8.3.1       Fonctions de copie       49         8.3.2       Fonctions de comparaison       49         8.3.4       Fonctions de recherche       50         8.4		0.1	_						
6.1.3 Environnements de typage       39         6.1.4 Jugements de typage       39         6.1.5 Programme       40         6.1.6 Flot de contrôle       40         6.1.7 Left values       40         6.1.8 Expressions       41         6.1.9 Fonctions       42         6.1.10 Instructions       42         6.2.1 Programmes non typables       43         6.2.2 Incohérences       43         7 Analyse de provenance des pointeurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string.h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de copie       49         8.3.3 Fonctions de recherche       50         8.4 Typage des primitives       50         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53									
6.1.4 Jugements de typage       39         6.1.5 Programme       40         6.1.6 Flot de contrôle       40         6.1.7 Left values       40         6.1.8 Expressions       41         6.1.9 Fonctions       42         6.1.10 Instructions       42         6.2 Limitations       43         6.2.1 Programmes non typables       43         6.2.2 Incohérences       43         7 Analyse de provenance des pointeurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string.h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53				*-					
6.1.5 Programme       40         6.1.6 Flot de contrôle       40         6.1.7 Left values       40         6.1.8 Expressions       41         6.1.9 Fonctions       42         6.1.10 Instructions       42         6.2 Limitations       43         6.2.1 Programmes non typables       43         6.2.2 Incohérences       43         7 Analyse de provenance des pointeurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string.h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de recherche       50         8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53									
6.1.6 Flot de contrôle       40         6.1.7 Left values       40         6.1.8 Expressions       41         6.1.9 Fonctions       42         6.1.10 Instructions       42         6.2.1 Limitations       43         6.2.1 Programmes non typables       43         6.2.2 Incohérences       43         7 Analyse de provenance des pointeurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53									
6.1.7 Left values       40         6.1.8 Expressions       41         6.1.9 Fonctions       42         6.1.10 Instructions       42         6.2 Limitations       43         6.2.1 Programmes non typables       43         6.2.2 Incohérences       43         7 Analyse de provenance des pointeurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53									
6.1.8 Expressions       41         6.1.9 Fonctions       42         6.1.10 Instructions       42         6.2 Limitations       43         6.2.1 Programmes non typables       43         6.2.2 Incohérences       43         7 Analyse de provenance des pointeurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53									
6.1.9 Fonctions       42         6.1.10 Instructions       42         6.2 Limitations       43         6.2.1 Programmes non typables       43         6.2.2 Incohérences       43         7 Analyse de provenance des pointeurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53									
6.1.10 Instructions       42         6.2 Limitations       43         6.2.1 Programmes non typables       43         6.2.2 Incohérences       43         7 Analyse de provenance des pointeurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string.h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53				-					
6.2 Limitations       43         6.2.1 Programmes non typables       43         6.2.2 Incohérences       43         7 Analyse de provenance des pointeurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de recherche       50         8.4 Fonctions de recherche       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53									
6.2.1 Programmes non typables       43         6.2.2 Incohérences       43         7 Analyse de provenance des pointeurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.4 Typage des primitives       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53		6 9							
6.2.2 Incohérences       43         7 Analyse de provenance des pointeurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string.h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53		0.2			_				
7 Analyse de provenance des pointeurs       45         7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string.h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53				•					
7.1 Éditions et ajouts       45         7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string.h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.3 Typage des primitives       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53			0.2.2	incoherences	45				
7.2 Propriété d'isolation mémoire       45         8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string.h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53	7	Ana	lyse de	provenance des pointeurs	_				
8 Analyse de terminaison des chaînes C       47         8.1 But       47         8.2 Approche       48         8.3 Annotation de string.h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53		7.1		· · · · · · · · · · · · · · · · · · ·	45				
8.1 But       47         8.2 Approche       48         8.3 Annotation de string.h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53		7.2	Propri	été d'isolation mémoire	45				
8.1 But       47         8.2 Approche       48         8.3 Annotation de string.h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53	8	Ana	lyse de	e terminaison des chaînes C	47				
8.2 Approche       48         8.3 Annotation de string.h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53		8.1	But .		47				
8.3 Annotation de string.h       49         8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation		8.2							
8.3.1 Fonctions de copie       49         8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation									
8.3.2 Fonctions de concaténation       49         8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation				<u> </u>	49				
8.3.3 Fonctions de comparaison       49         8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53									
8.3.4 Fonctions de recherche       50         8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53									
8.3.5 Fonctions diverses       50         8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation			8.3.4						
8.4 Typage des primitives       51         8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation									
8.5 Extensions au système de types       51         8.6 Résultats       51         III Expérimentation       53		8.4							
8.6 Résultats				-					
III Expérimentation 53				• • • • • • • • • • • • • • • • • • • •					
<del>-</del>		3							
9 Implantation 55	II	III Expérimentation 53							
	9	Imn	lantati	on	55				

vii	i		TAI	3LE	DES	S M	ATI	ÈR	RES
	9.1 9.2 9.3	Langages intermédiaires					· · · · · ·		57 57 57 58 58
	10.1 10.2 10.3 10.4 <b>Con</b>	de de cas : un pilote de carte graphique  Description du problème				• •			65 66 66 67 69
Δ	11.2	Perspectives							69 <b>71</b>
		les figures							<b>76</b>
Ré	férei	nces web							77
Bi	bliog	graphie							<b>7</b> 9



## Introduction

# Première partie

# Méthodes formelles pour la sécurité

### SYSTÈMES D'EXPLOITATION

Le système d'exploitation est le programme qui permet à un système informatique d'exécuter d'autre programmes. Son rôle est donc capital et ses responsabilités multiples. Dans ce chapitre, nous allons voir quel est son rôle, et comment il peut être implanté. Pour ce faire, nous étudierons l'exemple d'une architecture Intel 32 bits, et d'un noyau Linux 2.6.

Pour une description plus détaillée des rôles d'un système d'exploitation ainsi que plusieurs cas d'étude détaillés, on pourra se référer à [Tan07].

#### 2.1 Rôle d'un système d'exploitation

Un ordinateur est constitué de nombreux composants matériels : microprocesseur, mémoire, et divers périphériques. Pourtant, au niveau de l'utilisateur, des dizaines de logiciels permettent d'effectuer toutes sortes de calculs et de communications. Le système d'exploitation permet de faire l'interface entre ces niveaux d'abstraction.

Au cours de l'histoire des systèmes informatiques, la manière de les programmer a beaucoup évolué. Au départ, les programmeurs avaient accès au matériel dans son intégralité : toute la mémoire pouvait être accédée, toutes les instructions pouvaient être utilisées.

Néanmoins c'est un peu restrictif, puisque cela ne permet qu'à une personne d'interagir avec le système. Dans la seconde moitié des années 60, sont apparus les premiers systèmes "à temps partagé", permettant à plusieurs utilisateurs de travailler en même temps.

Permettre l'exécution de plusieurs programmes en même temps est une idée révolutionnaire, mais elle n'est pas sans difficultés techniques : en effet les ressources de la machine doivent être aussi partagées entre les utilisateurs et les programmes. Par exemple, plusieurs programmes vont utiliser le processeur les uns à la suite des autres (partage *temporel*); et chaque programme aura à sa disposition une partie de la mémoire principale, ou du disque dur (partage *spatial*).

Si deux programmes (ou plus) s'exécutent de manière concurrente sur le même matériel, il faut s'assurer que l'un ne puisse pas écrire dans la mémoire de l'autre, ou que les deux utilisent la carte réseau les uns à la suite des autres. Ce sont des rôles du système d'exploitation.

Cela passe donc par une limitation des possibilités du programme : plutôt que de permettre n'importe quel type d'instruction, il communique avec le système d'exploitation. Celui-ci centralise donc les appels au matériel, ce qui permet d'abstraire certaines opérations.

Par exemple, si un programme veut copier des données depuis un cédérom vers la mémoire principale, il devra interroger le bus SATA, interroger le lecteur sur la présence d'un disque dans le lecteur, activer le moteur, calculer le numéro de trame des données sur le disque, demander la lecture, puis déclencher une copie de la mémoire.

Si dans un autre cas il désire récupérer des données depuis une mémorette USB, il devrait interroger le bus USB, rechercher le bon numéro de périphérique, le bon numéro de canal dans celui-ci, lui appliquer une commande de lecture au bon numéro de bloc, puis copier la mémoire.

Ces deux opérations, bien qu'elles aient le même but (copier de la mémoire depuis un périphérique amovible), ne sont pas effectuées en pratique de la même manière. C'est pourquoi le système d'exploitation fournit les notions de fichier, lecteur, etc : le programmeur n'a plus qu'à utiliser des commandes de haut niveau ("monter un lecteur", "ouvrir un fichier", "lire dans un fichier") et selon le type de lecteur, le système d'exploitation effectuera les actions appropriées.

En résumé, un système d'exploitation est l'intermédiaire entre le logiciel et le matériel, et en particulier assure les rôles suivants :

A affiner ou suporimer

- Gestion des processus : un système d'exploitation peut permettre d'exécuter plusieurs programmes à la fois. Il faut alors orchestrer ces différents processus et les séparer en terme de temps et de ressources partagées.
- Gestion de la mémoire : chaque processus, en plus du noyau, doit disposer d'un espace mémoire différent. C'est-à-dire qu'un processus ne doit pas pouvoir interférer avec un autre.
- Gestion des fichiers : les processus peuvent accéder à une hiérarchie de fichiers, indépendamment de la manière d'y accéder.
- Gestion des périphériques : le noyau étant le seul code ayant des privilèges, c'est lui qui doit communiquer avec les périphériques matériels.
- Abstractions: le noyau fournit aux programmes une interface unifiée, permettant de stocker des informations de la même manière sur un disque dur ou une clef USB (alors que l'accès se déroulera de manière très différente en pratique).

#### 2.2 Architecture Intel

L'implantation d'un système d'exploitation est très proche du matériel sur lequel il s'exécute. Pour étudier une implantation en particulier, voyons ce que permet le matériel lui-même.

Dans cette section nous décrivons le fonctionnement d'un processeur utilisant une architecture Intel 32 bits. Les exemples de code seront écrits en syntaxe AT&T, celle que comprend l'assembleur GNU.

La référence pour la description de l'assembleur Intel est la documentation du constructeur [Int]; une bonne explication de l'agencement dans la pile peut aussi être trouvée dans [One96].

#### 2.2.1 Assembleur

Pour faire des calculs, le processeur est composé de registres, qui sont des petites zones de mémoire interne, et peut accéder à la mémoire principale.

La mémoire principale contient divers types des données :

- le code des programmes à exécuter
- les données à disposition des programmes
- la pile d'appels

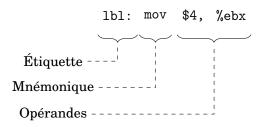
La pile d'appels est une zone de mémoire qui est notamment utilisée pour tenir une trace des calculs en cours. Par exemple, c'est ici que seront stockées les données propres à chaque fonction appelée : paramètres, adresse de retour et variables locales. La pile est manipulée par un pointeur de pile (*stack pointer*), qui est l'adresse du "haut de la pile". On peut la manipuler en empilant des données (les placer au niveau du pointeur de pile et déplacer celui si) ou dépilant des données (déplacer le pointeur de pile dans l'autre sens et retourner la valeur présente à cet endroit).

L'état du processeur est défini par la valeur de ses registres, qui sont des petites zones de mémoire interne (quelques bits chacuns). Par exemple, la valeur du pointeur de pile est stockée dans ESP. Le registre EBP, couplé à ESP sert à adresser les variables locales et paramètres d'une fonction, comme ce sera expliqué dans la section 2.2.2.

L'adresse de l'instruction courante est accessible dans le registre EIP.

En plus de ces registres spéciaux, le processeur possède de nombreux registres génériques, qui peuvent être utilisés pour réaliser des calculs intermédiaires. Ils sont nommés EAX, EBX, ECX, EDX, ESI et EDI. Ils peuvent être utilisés pour n'importe quel type d'opération, mais certains sont spécialisés : par exemple il est plus efficace d'utiliser EAX en accumulateur, ou ECX en compteur.

Les calculs sont décrits sous forme d'une suite d'instructions. Chaque instruction est composée d'un mnémonique et d'une liste d'opérandes. Les mnémoniques (mov, call, sub, etc) définissent un type d'opération à appliquer sur les opérandes. L'instruction peut aussi être précédée d'une étiquette, qui correspondra à son adresse.



Ces opérandes peuvent être de plusieurs types :

- un nombre, noté \$4
- le nom d'un registre, noté %eax
- une opérande mémoire, c'est à dire le contenu de la mémoire à une adresse effective. Cette adresse effective peut être exprimée de plusieurs manières :
  - directement : addr
  - indirectement : (%ecx). L'adresse effective est le contenu du registre.
  - "base + déplacement" : 4(%ecx). L'adresse effective est le contenu du registre plus le déplacement (4 ici).

En pratique il y a des modes d'adressage plus complexes, et toutes les combinaisons ne sont pas possibles, mais ceux-ci suffiront à décrire les exemples suivants :

- mov src, dst copie le contenu de src dans dst.
- add src, dst calcule la somme des contenus de src et dst et place ce résultat dans dst.

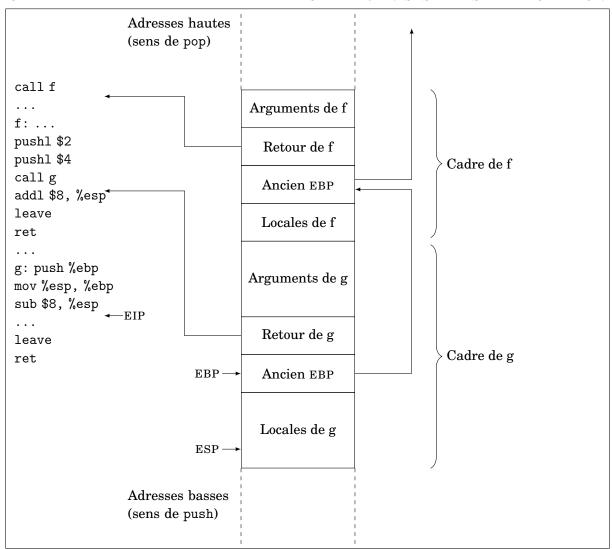


FIGURE 2.1 – Cadres de pile.

- push src place src sur la pile, c'est à dire que cette instruction enlève au pointeur de pile ESP la taille de src, puis place src à l'adresse mémoire de la nouvelle valeur ESP.
- pop src réalise l'opération inverse : elle charge le contenu de la mémoire à l'adresse ESP dans src puis incrémente ESP de la taille correspondante.
- jmp addr saute à l'adresse addr : c'est l'équivalent de mov addr, %eip.
- call addr sert aux appels de fonction : cela revient à push %eip puis jmp addr.
- rest sert à revenir d'une fonction : c'est l'équivalent de pop %eip.

#### 2.2.2 Fonctions et conventions d'appel

Mettre des vrais combres plutôt que lu symbolique

Dans le langage d'assemblage, il n'y a pas de notion de fonction; mais call et ret permettent de sauvegarder et de restaurer une adresse de retour, ce qui permet de faire un saut et revenir à l'adresse initiale. Ce système permet déjà de créer des procédures, c'est-à-dire des fonctions sans arguments ni valeur de retour.

Pour gérer ceux-ci, il faut que les deux morceaux (appelant et appelé) se mettent d'accord sur une convention d'appel commune. La convention utilisée sous GNU/Linux est appelée *cdecl* et possède les caractéristiques suivantes :

- la valeur de retour d'une fonction est stockée dans EAX
- EAX, ECX et EDX peuvent être écrasés sans avoir à les sauvegarder
- les arguments sont placés sur la pile (et enlevés) par l'appelant. Les paramètres sont empilés de droite à gauche.

Pour accéder à ses paramètres, une fonction peut donc utiliser un adressage relatif à ESP. Cela peut fonctionner, mais cela complique les choses si elle contient aussi des variables locales. En effet, les variables locales sont placées sur la pile, au dessus des (c'est à dire, empilées après) paramètres, augmentant le décalage.

Pour simplifier, la pile est organisée en cadres logiques : chaque cadre correspond à un niveau dans la pile d'appels de fonctions. Si f appelle g, qui appelle h, il y aura dans l'ordre sur la pile le cadre de f, celui de g puis celui de h.

Ces cadres sont chainés à l'aide du registre EBP : à tout moment, EBP contient l'adresse du cadre de l'appelant.

Prenons exemple sur la figure 2.1 : pour appeler g(4,2), f empile les arguments de droite à gauche. L'instruction call g empile l'adresse de l'instruction suivante sur la pile puis saute au début de g.

Au début de la fonction, les trois instructions permettent de sauvegarder l'ancienne valeur de EBP, faire pointer EBP à une endroit fixe dans le cadre de pile, puis allouer 8 octets de mémoire pour les variables locales.

Dans le corps de la fonction g, on peut donc se référer aux variables locales par -4(%ebp), -8(%ebp), etc, et aux arguments par 8(%ebp), 12(%ebp), etc.

À la fin de la fonction, l'instruction leave est équivalente à mov %ebp, %esp puis pop %ebp et permet de défaire le cadre de pile, laissant l'adresse de retour en haut de pile. Le ret final la dépile et y saute.

#### 2.2.3 Tâches, niveaux de privilèges

Sans mécanisme particulier, le processeur exécuterait uniquement une suite d'instruction à la fois. Pour lui permettre d'exécuter plusieurs tâches, un système de partage du temps existe.

À des intervalles de temps réguliers, le système est programmé pour recevoir une interruption. C'est une condition exceptionnelle (au même titre qu'une division par zéro) qui fait sauter automatiquement le processeur dans une routine de traitement d'interruption. À cet endroit le code peut sauvegarder les registres et restaurer un autre ensemble de registres, ce qui permet d'exécuter plusieurs tâches de manière entrelacée. Si l'alternance est assez rapide, cela peut donner l'illusion que les programmes s'exécutent en parallèle. Comme l'interruption peut survenir à tout moment, on parle de multitâche préemptif.

En plus de cet ordonnancement de processus, l'architecture Intel permet d'affecter des niveaux de privilège à ces tâches, en restreignant le type d'instructions exécutables, ou en donnant un accès limité à la mémoire aux tâches de niveaux moins élevés.



FIGURE 2.2 – Les différents *rings*. Seul le *ring* 0 a accès au hardware via des instructions privilégiées. Pour accéder aux fonctionnalités du noyau, les programmes utilisateur doivent passer par des appels système.

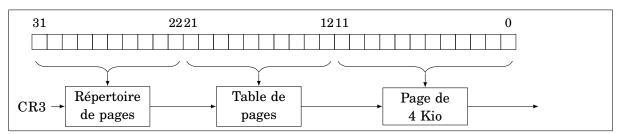


FIGURE 2.3 - Implantation de la mémoire virtuelle

Il y a 4 niveaux de privilèges (nommés aussi *rings* - figure 2.2) : le *ring* 0 est le plus privilégié, le *ring* 3 le moins privilégié. Dans l'exemple précédent, on pourrait isoler l'ordonnanceur de processus en le faisant s'exécuter en *ring* 0 alors que les autres tâches seraient en *ring* 3.

#### 2.2.4 Mémoire virtuelle

À partir du moment où plusieurs processus s'exécutent de manière concurrente, un problème d'isolation se pose : si un processus peut lire dans la mémoire d'un autre, des informations peuvent fuiter; et s'il peut y écrire, il peut en détourner l'exécution.

Le mécanisme de mémoire virtuelle permet de donner à deux tâches une vue différente de la mémoire : c'est à dire que vue de tâches différentes, une adresse contiendra une valeur différente.

Ce mécanisme est contrôlé par valeur du registre CR3 : les 10 premiers bits d'une adresse virtuelle sont un index dans le répertoire de pages qui commence à l'adresse contenue dans CR3. À cet index, se trouve l'adresse d'une table de pages. Les 10 bits suivants de l'adresse sont un index dans cette page, donnant l'adresse d'une page de 4 kibioctets (figure 2.3).

En ce qui concerne la mémoire, les différentes tâches ont une vision différente de la mémoire physique : c'est-à-dire que deux tâches lisant à une même adresse peuvent avoir un résultat différent. C'est le concept de mémoire virtuelle (fig 2.4).

'aire cette figure

Redite qui n'aporte pas plus l'explication

#### 2.3 Cas de Linux

Dans cette section, nous allons voir comment ces mécanismes sont implantés dans le noyau Linux. Une description plus détaillée pourra être trouvée dans [BC05], ou pour le cas de la mémoire virtuelle, [Gor04].

Deux rings sont utilisés : en ring 0, le code noyau et en ring 3, le code utilisateur.

2.3. CAS DE LINUX

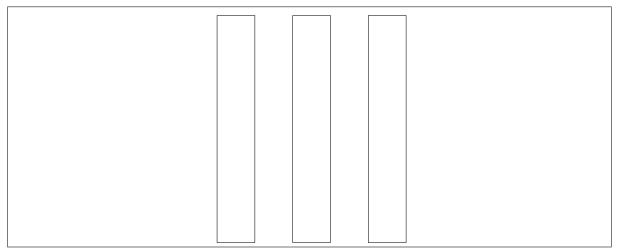


FIGURE 2.4 – Mécanisme de mémoire virtuelle.

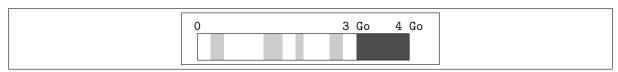


FIGURE 2.5 – L'espace d'adressage d'un processus. En gris clair, les zones accessibles à tous les niveaux de privilèges : code du programme, bibliothèques, tas, pile. En gris foncé, la mémoire du noyau, réservée au mode privilégié.

Une notion de tâche similaire à celle décrite dans la section 2.2.3 existe : elles s'exécutent l'une après l'autre, le changement s'effectuant sur interruptions.

Pour faire appel aux services du noyau, le code utilisateur doit faire appel à des appels systèmes, qui sont des fonctions exécutées par le noyau. Chaque tâche doit donc avoir deux piles : une pile "utilisateur" qui sert pour l'application elle-même, et une pile "noyau" qui sert aux appels système.

Grâce à la mémoire virtuelle, chaque processus possède sa propre vue de la mémoire dans son espace d'adressage (figure 2.5), et donc chacun un ensemble de tables de pages et une valeur de CR3associée. Au moment de changer le processus en cours, l'ordonnanceur charge donc le CR3du nouveau processus.

Les adresses basses (inférieures à PAGE\_OFFSET = 3 Gio = 0xc0000000) sont réservées à l'utilisateur. On y trouvera par exemple :

- le code du programme
- les données du programmes (variables globales)
- la pile utilisateur
- le tas (mémoire allouée par malloc et fonctions similaires)
- · les bibliothèques partagées

Au dessus de PAGE\_OFFSET, se trouve la mémoire réservée au noyau. Cette zone contient le code du noyau, les piles noyau des processus, etc.

#### 2.3.1 Appels système

clarifier encore tout ça Les programmes utilisateur s'exécutant en *ring* 3, ils ne peuvent pas contenir d'instructions privilégiées, et donc ne peuvent pas accéder directement au matériel (c'était le but!). Pour qu'ils puissent interagir avec le système (afficher une sortie, écrire sur le disque...), le mécanisme des appels système est nécessaire. Il s'agit d'une interface de haut niveau entre les *rings* 3 et 0. Du point de vue du programmeur, il s'agit d'un ensemble de fonctions C "magiques" qui font appel au système d'exploitation pour effectuer des opérations.

Voyons ce qui se passe derrière la magie apparente. Une explication plus détaillée est disponible dans la documentation fournie par Intel [Int].

#### Dans la bibliothèque C

Il y a bien une fonction getpid présente dans la bibliothèque C du système. C'est la fonction qui est directement appelée par le programme. Cette fonction commence par placer le numéro de l'appel système (noté \_\_NR\_getpid, valant 20 ici) dans EAX, puis les arguments éventuels dans les registres (EBX, ECX, EDX, ESI puis EDI). Une interruption logicielle est ensuite déclenchée (int 0x80).

#### Dans la routine de traitement d'interruption

Étant donné la configuration du processeur <sup>1</sup>, elle sera traitée en *ring* 0, à un point d'entrée prédéfini (arch/x86/kernel/entry\_32.S, ENTRY(system\_call)).

```
# system call handler stub
ENTRY(system_call)
        RINGO_INT_FRAME
                                                # can't unwind into user space anyway
        pushl %eax
                                           # save orig_eax
        CFI_ADJUST_CFA_OFFSET 4
        SAVE_ALL
        GET_THREAD_INFO(%ebp)
                                         # system call tracing in operation / emulation
        test1 $_TIF_WORK_SYSCALL_ENTRY,TI_flags(%ebp)
        jnz syscall_trace_entry
        cmpl $(nr_syscalls), %eax
        jae syscall_badsys
syscall_call:
        call *sys_call_table(,%eax,4)
        movl %eax,PT_EAX(%esp)
                                               # store the return value
        # ...
        INTERRUPT_RETURN
```

L'exécution reprend donc en *ring* 0, avec dans ESP le pointeur de pile noyau du processus. Les valeurs des registres ont été préservées, la macro SAVE\_ALL les place sur la pile. Ensuite, à l'étiquette syscall\_call, le numéro d'appel système (toujours dans EAX) sert d'index dans le tableau de fonctions sys\_call\_table.

<sup>1.</sup> Il est impropre de dire que le processeur est configuré — tout dépend uniquement de l'état de certains registres, ici la Global Descriptor Table et les Interrupt Descriptor Tables.

#### Dans l'implantation de l'appel système

Puisque les arguments sont en place sur la pile, comme dans le cas d'un appel de fonction "classique", la convention d'appel *cdecl* est respectée. La fonction implantant l'appel système, nommée sys\_getpid, peut donc être écrite en C.

On trouve cette fonction dans kernel/timer.c:

```
SYSCALL_DEFINEO(getpid)
{
     return task_tgid_vnr(current);
}
```

La macro SYSCALL\_DEFINEO nomme la fonction sys\_getpid, et définit entre autres des points d'entrée pour les fonctionnalités de débogage du noyau. À la fin de la fonction, la valeur de retour est placée dans EAX, conformément à la convention *cdecl*.

#### Retour vers le ring 3

Au retour de la fonction, la valeur de retour est placée à la place de EAX là où les registres ont été sauvegardés sur la pile noyau (PT\_EFLAGS(%esp)). L'instruction iret (derrière la macro INTERRUPT\_RETURN) permet de restaurer les registres et de repasser en mode utilisateur, juste après l'interruption. La fonction de la bibliothèque C peut alors retourner au programme appelant.

#### 2.4 Sécurité des appels système

On a vu que les appels systèmes permettent aux programmes utilisateur d'accéder au services du noyau. Ils forment donc une interface particulièrement sensible aux problèmes de sécurité.

Comme pour toutes les interfaces, on peut être plus ou moins fin. D'un côté, une interface pas assez fine serait trop restrictive et ne permettrait pas d'implémenter tout type de logiciel. De l'autre, une interface trop laxiste ("écrire dans tel registre matériel") empêche toute isolation. Il faut donc trouver la bonne granularité.

Nous allons présenter ici une difficulté liée à la manipulation de mémoire au sein de certains types d'appels système.

Il y a deux grands types d'appels systèmes : d'une part, ceux qui renvoient un simple nombre, comme getpid qui renvoie le numéro du processus appelant.

```
pid_t pid = getpid();
printf("%d\n", pid);
```

Ici, pas de difficulté particulière : la communication entre le *ring* 0 et le *ring* 3 est faite uniquement à travers les registres, comme décrit dans la section 2.3.1.

Mais la plupart des appels systèmes communiquent de l'information de manière indirecte, à travers un pointeur. L'appellant alloue une zone mémoire dans son espace d'adressage et passe un pointeur à l'appel système. Ce mécanisme est utilisé par exemple par la fonction gettimeofday (figure 2.6).

FIGURE 2.6 – Appel de gettimeofday

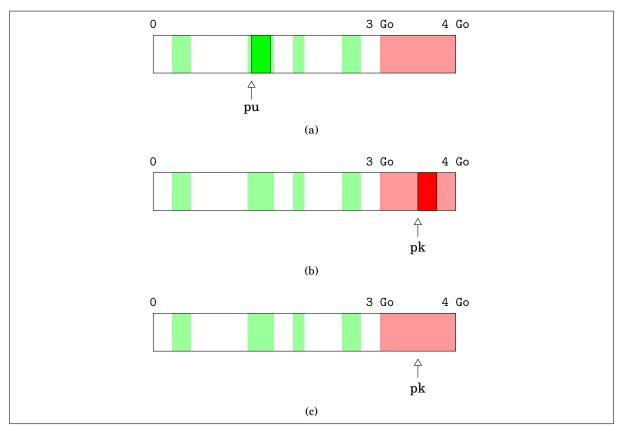


FIGURE 2.7 - Zones mémoire

FIGURE 2.8 - Implantation de l'appel système gettimeofday

Considérons une implémentation naïve de cet appel système qui écrirait directement à l'adresse pointée. La figure 2.7a présente ce qui se passe lorsque le pointeur fourni est dans l'espace d'adressage du processus : c'est le cas d'utilisation normal et l'écriture est donc possible.

Si l'utilisateur passe un pointeur dont la valeur est supérieure à 0xc0000000 (figure 2.7b), que se passe-t'il? Comme le déréférencement est fait dans le code du noyau, il est également fait en *ring* 0, et va pouvoir être réalisé sans erreur : l'écriture se fait et potentiellement une structure importante du noyau est écrasée.

Un utilisateur malicieux peut donc utiliser cet appel système pour écrire à n'importe quelle adresse dans l'espace d'adressage du noyau. Ce problème vient du fait que l'appel système utilise les privilèges du noyau au lieu de celui qui contrôle la valeur des paramètres sensibles. Celà s'appelle le *Confused Deputy Problem*[Har88].

La bonne solution est de tester dynamiquement la valeur du pointeur : si la valeur du pointeur est supérieure à 0xc0000000, il faut indiquer une erreur avant d'écrire (figure 2.7c. Sinon, cela ne veut pas dire que le déréférencement se fera sans erreur, mais au moins le noyau est protégé.

Dans le noyau, un ensemble de fonctions permet d'effectuer des copies sûres. La fonction access\_ok réalise le test décrit précédemment. Les fonctions copy\_from\_user et copy\_to\_user réalisent une copie de la mémoire après avoir fait ce test. Ainsi, l'implantation correcte de l'appel système gettimeofday fait appel à celle-ci (figure 2.8).

Pour préserver la sécurité du noyau, il est donc nécessaire de vérifier la valeur de tous les pointeurs dont la valeur est contrôlée par l'utilisateur. Cette conclusion est assez contraignante, puisqu'il existe de nombreux endroits dans le noyau où des données proviennent de l'utilisateur. Il est donc raisonnable de vouloir vérifier automatiquement et statiquement l'absence de tels défauts.

#### **TYPAGE**

Dans ce chapitre, nous explorons la notion de type dans les langages de programmation. Tout d'abord pourquoi elle existe et en quoi elle aide à rendre les programmes plus sûrs. Il y a autant de système de types que de langages de programmation, donc nous présenterons ensuite une taxonomie de ces systèmes en les regroupant par caractéristiques communes. Cette classification sera appuyée par des exemples de code C[ISO99, KR88], OCaml[\*1] [CMP03], Haskell[\*2] [PJ03, OGS08], Python[\*3] et Perl[\*4] [Wal00].

#### 3.1 Présentation et but

Nous avons vu dans le chapitre 2 qu'au niveau du langage machine, les seules données qu'un ordinateur manipule sont des nombres. Selon les opérations effectuées, ils seront interprétés comme des entiers, des adresses mémoires, ou des caractères. Pourtant il est clair que certaines opérations n'ont pas de sens : par exemple, ajouter deux adresses, ou déréférencer le résultat d'une division sont des comportements qu'on voudrait pouvoir empêcher.

En un mot, le but du typage est de classifier les objets et de restreindre les opérations possibles selon la classe d'un objet : "ne pas ajouter des pommes et des oranges". Le modèle qui permet cette classification est appelé *système de types* et est en général constitué d'un ensemble de *règles de typage*, comme "un entier plus un entier égale un entier".

#### 3.2 Taxonomie

La définition d'un langage de programmation introduit la plupart du temps celle d'un système de types. Il y a donc de nombreux systèmes de types différents, dont nous pouvons donner une classification sommaire.

#### 3.2.1 Dynamique, statique, mixte

Il y a deux grandes familles de systèmes de types, selon quand se fait la vérification de types. On peut en effet l'effectuer au moment de l'exécution, ou au contraire prévenir les erreurs à l'exécution en la faisant au moment de la compilation (ou avant l'interprétation).

```
>>> a = 3
>>> c = 4.5
>>> type(a)
<type 'int'>
>>> a+a
>>> type(a+a)
<type 'int'>
>>> a+c
7.5
>>> type(a+c)
<type 'float'>
>>> def d(x):
        return 2*x
. . .
>>> type(d)
<type 'function'>
>>> a+d
Traceback (most recent call last):
 File "<stdin>", line 1, in <module>
TypeError: unsupported operand type(s) for +: 'int' and 'function'
```

FIGURE 3.1 – Session Python présentant le typage dynamique

#### Typage dynamique

La première est le typage dynamique. Pour différencier les différents types de données, on ajoute une étiquette à chaque valeur. Dans tout le programme, on ne manipulera que des valeurs étiquetées, c'est à dire des couples (donnée, nom de type). Si on veut réaliser l'opération (0x00000001, Int) + (0x0000f000, Int), on vérifie tout d'abord qu'on peut réaliser l'opération + entre deux Int. Ensuite on réalise l'opération elle même, qu'on étiquette avec le type du résultat : (0x0000f001, Int). Si au contraire on tente d'ajouter deux adresses (0x2e8d5a90, Addr) + (0x76a5e0ec, Addr), la vérification échoue et l'opération s'arrête avec une erreur.

La figure 3.1 est une session interactive Python qui illustre le typage dynamique. Chaque variable, en plus de sa valeur, possède une étiquette qui permet d'identifier le type de celle-ci. On peut accéder au type d'une valeur x avec la construction type(x).

Au moment de réaliser une opération comme +, l'interpréteur Python vérifie les types des opérandes : s'ils sont compatibles, il créé une valeur de résultat, et sinon il lève une exception.

Comme l'implémentation elle-même des fonction a accès aux informations de type, elle peut faire des traitements particuliers. Par exemple, pour l'addition de a (de type entier) et de c (de type flottant), la fonction d'addition va d'abord convertir a en flottant, puis réaliser l'addition dans le domaine des flottants.

#### Typage statique

Le typage dynamique est simple à comprendre puisque toute les vérifications se font dans la sémantique dynamique (ie, à l'exécution). C'est à double tranchant : d'une part, cela permet 3.2. TAXONOMIE

```
def f(b):
    x = None
    r = None
    if b:
        x = 1
    else:
        x = lambda y: y + 1
    b = not b
    if b:
        r = x (1)
    else:
        r = x + 1
    return r
```

FIGURE 3.2 – Fonction Python non typable statiquement.

d'être plus flexible, mais d'autre part, cela permet à des programmes incorrects d'être exécutés.

On peut lire le code source d'un programme et essayer de "deviner" quels seront les types des différentes expressions. Dans certains cas, cela n'est pas possible (fig 3.2); mais lorsqu'on peut conclure cela élimine la nécessité de faire les tests de type dynamiques car on a réalisé le typage *statiquement*.

Bien sûr, deviner n'est pas suffisant : il faut formaliser cette analyse. Dans le cas dynamique, ce sont les fonctions elles-mêmes qui réalisent les tests de type et qui appliquent des règles comme "si les arguments ont pour type int alors la valeur de retour a pour type int" : la fonction qui réalise ce test sur les valeurs. Dans le cas statique, c'est le compilateur (ou l'interpréteur) qui réalise ce test sur les expressions non évaluées. En appliquant de proche en proche un ensemble de règles (liées uniquement au langage de programmation), on finit par associer à chaque sous-expression du programme un type.

Benjamin Pierce résume cette approche dans cette définition très générale :

**Définition 3.1 (Système de types)** Un système de types est une méthode syntaxique tractable qui vise à prouver l'absence de certains comportements de programmes en classifiant leurs phrases selon le genre de valeurs qu'elles produisent. [Pie02]

A première vue, cela semble moins puissant que le typage dynamique : en effet, il existe des programmes qui s'exécuteront sans erreur de type mais sur lesquels le typage statique ne peut s'appliquer. Dans la figure 3.2, on peut voir par une simple analyse de cas que si on fournit un booléen à f, elle retourne un entier. Mais selon la valeur de b, la variable x contiendra une valeur de type entier ou fonction.

Même si cet exemple est construit artificiellement, il illustre le problème suivant : les types statiques demandent un certain effort et au programmeur et au compilateur. Mais Dans le cas où le typage statique est possible, les garanties sont importantes : les valeurs portées par une variable auront toujours le même type. Par voie de conséquence, la vérification dynamique de types réussira toujours, et on peut la supprimer. Il est également possible de supprimer toutes les étiquettes de typage : on parle de *type erasure*. Une conséquence heureuse de cette suppression est que l'exécution de ce programme se fera de manière plus rapide.

```
Object o = new Integer(3);
Float f = (Float) o;
```

FIGURE 3.3 - Transtypage en Java

Connaître les types à la compilation permet aussi de réaliser plus d'optimisations. Par exemple, en Python, considérons l'expression y = x - x. Sans information sur le type de x, aucune simplification n'est possible : l'implémentation de la différence sur ce type est une fonction quelconque, sans propriétés particulières *a priori*. Si au contraire, on sait que x est un entier, on peut en déduire que y = 0, sans réaliser la soustraction (si c'était la seule utilisation de x, le calcul de x aurait alors pu être éliminé).

#### 3.2.2 Fort, faible, sound

Si un système de types statique permet d'éliminer totalement la nécessité de réaliser des tests de typage, on dit qu'il est *fort*. Mais ce n'est que rarement le cas. En effet, il peut y avoir des constructions au sein du langage qui permettent de contourner le système de types, comme un opérateur de transtypage3.3. À l'exécution, une erreur de types est levée:

```
Exception in thread "main" java.lang.ClassCastException:
    java.lang.Integer cannot be cast to java.lang.Float
    at Cast.main(Cast.java:5)
```

3.2. TAXONOMIE

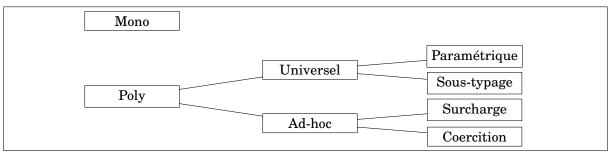


FIGURE 3.4 – Les différents types de polymorphisme.



#### 3.2.3 Polymorphisme

Dans le cas du typage statique, restreindre une opération à un seul type de données peut être assez restrictif.

Par exemple, quel doit être le type d'une fonction qui trie un tableau?

#### Monomorphisme

Une première solution peut être de forcer des types concrets, c'est à dire qu'une même fonction ne pourra s'appliquer qu'à un seul type de données.

Il est confortable pour le programmeur de n'avoir à écrire un algorithme qu'une seule fois, indépendamment du type des éléments considérés.

Il existe deux grandes classes de systèmes de types introduisant du polymorphisme.

#### Polymorphisme universel

Le polymorphisme est dit universel si toute fonction générique peut s'appliquer à n'importe quel type.

#### Polymorphisme ad-hoc

Le polymorphisme est ad-hoc si les fonctions génériques ne peuvent s'appliquer qu'à un ensemble de types prédéfini.

#### Polymorphisme paramétrique

[Mil78]

Historique + citer le papier de Milner sur le polymor phisme

CHAPITRE 3. TYPAGE

```
let rec append lx ly =
 match lx with
    []
           -> ly
    | x::xs -> x::append lx ly
```

FIGURE 3.5 – Fonction de concaténation de listes en OCaml.

```
show :: Show a => a -> String
read :: Read a => String -> a
showRead :: String -> String
showRead x = show (read x)
```

FIGURE 3.6 – Cas d'ambigüité avec de la surcharge ad-hoc.

[Ker81]

La fonction de la figure 3.5 n'opère que sur la structure du type liste (en utilisant ses constructeurs [] et (::)ainsi que le filtrage) : les éléments de 1x et 1y ne sont pas manipulés à part pour les transférer dans le résultat.

Moralement, cette fonction est donc indépendante du type de données contenu dans la liste : elle pourra agir sur des listes de n'importe quel type d'élément.

Plutôt qu'un type, on peut lui donner le schéma de types suivant :

```
append: \forall a.a \text{list} -> a \text{list} -> a \text{list}
```

C'est à dire que append peut être utilisé avec n'importe quel type concret a en substituant les variables quantifiées (on parle d'instanciation).

#### Polymorphisme par sous-typage

ypage,classe,méthode,hérchage ins langages définissent la notion de sous-typage. C'est une relation d'ordre partiel sur les types, qui modélise la relation "est un". Chaque sous-classe peut redéfinir le comportement de chaque méthode de ses superclasses.

#### Polymorphisme par surcharge

Considérons l'opération d'addition: +. On peut considérer que certains types l'implémentent, et pas d'autres : ajouter deux flottants ou deux entiers a du sens, mais pas ajouter deux pointeurs.

On dira que + est surchargé. À chaque site d'appel, il faudra résoudre la surcharge pour déterminer quelle fonction appeler.

Cela rend l'inférence de types impossible dans le cas général, puisque certaines constructions sont ambigües.

Dans le code Haskell de la figure 3.6, show peut s'appliquer à toutes les valeurs de types "affichables" et renvoie une représentation textuelle. read réalise le contraire avec les types "lisibles".

éritage, sousnultiple, late binling,Liskov

ntroduire l'inféence plus haut

3.3. EXEMPLES 23

Lorsqu'on compose ces deux fonctions, le type de la valeur intermédiaire est capital puisqu'il détermine les instances de show et read à utiliser.

#### Polymorphisme par coercition

#### Polymorphisme d'ordre supérieur

$$g f = (f true, f 2)$$

$$g: (\forall a.a -> a) -> (bool*int)$$

Pas inférable (annotations nécessaires).

#### 3.2.4 Expressivité, garanties, types dépendants

#### 3.3 Exemples

- 3.3.1 Faible dynamique : Perl
- 3.3.2 Faible statique: C
- 3.3.3 Fort dynamique: Python
- 3.3.4 Fort statique: OCaml
- 3.3.5 Fort statique à effets typés : Haskell
- 3.3.6 Theorem prover: Coq

## ÉTAT DE L'ART

L'analyse statique de programmes est un sujet de recherche actif depuis l'apparition de la science informatique.

L'analyse la plus simple consiste à traiter un programme comme du texte, et à y rechercher des motifs dangereux. Ainsi, utiliser des outils comme grep permet parfois de trouver un grand nombre de vulnérabilités[Spe05].

On peut continuer cette approche en recherchant des motifs mais en étant sensible à la syntaxe et au flot de contrôle du programme. Cette notion de semantic grep est présente dans l'outil Coccinelle [BDH+09, PTS+11] : on peut définir des patches sémantiques pour détecter ou lire coccinelle09 modifier des constructions particulières.

Dans le cas particulier des vulnérabilités liées à une mauvaise utilisation de la mémoire, les développeurs du noyau Linux ont ajouté un système d'annotations au code source. Un pointeur peut être décoré d'une annotation \_\_kernel ou \_\_user selon s'il est sûr ou pas. Celle-ci sont ignorées par le compilateur, mais un outil d'analyse statique ad-hoc nommé Sparse [65] peut être utilisé pour détecter les cas les plus simples d'erreurs.

Ce système d'annotations sur les types a été formalisé sous le nom de qualificateurs de types : chaque type peut être décoré d'un ensemble de qualificateurs (à la manière de const), et des règles de typage permettent d'établir des propriétés sur le programme. Ces analyses ont été implantée dans l'outil CQual [FFA99, STFW01, FTA02, JW04, FJKA06]. .

lister les applications

L'interprétation abstraite est une technique d'analyse générique qui permet de simuler statiquement tous les comportements d'un programme Cousot [CC77, CC92]. Un exemple d'application est de calculer les bornes de variations des variables pour s'assurer qu'aucun débordement de tableau n'est possible. Cette technique est très puissante mais possède plusieurs inconvénients. D'une part, pour réaliser une analyse interprocédurale il faut partir d'un point en particulier du programme (comme la fonction main). Cette hypothèse n'est pas facilement satisfaite dans un noyau de système d'exploitation, qui possède de nombreux points d'entrée. D'autre part, il est très difficile de faire passer à l'échelle un interpréteur abstrait [CCF<sup>+</sup>09, BBC<sup>+</sup>10].

L'approche par typage, plus légère, est séduisante. Pour les différents enjeux des systèmes de types statiques, on pourra se référer à [Pie02]. Il est possible d'encoder ce genre de propriétés dans un sytème de types, cf. [KcS07] et [LZ06].

On peut aller plus loin que les simples types et utiliser un langage de contrats : chaque fonction est annotée par des pré- et post-conditions sur la mémoire[DRS00].

Hoare

Du côté de l'analyse dynamique, [SAB10].

et Perl?

Ce que nous voulons vérifier peut être vue comme une propriété de flot. Un survey des problèmes et techniques existantes peut être trouvé dans [SM03].



 $Interpr\'{e} tation \ Abstraite: widening [Gra92], CGS \ [VB04], A str\'{e}: presentation [Mau04, CCF^+05], \\$ 

Divers: Taint sequences [CMP10],

Frama-C? CCurred?

# Deuxième partie

# Typage statique de langages impératifs

# SÉMANTIQUE D'UN LANGAGE IMPÉRATIF

Dans ce chapitre nous présentons un langage impératif permettant de modéliser C. Nous donnons sa syntaxe ainsi qu'une sémantique opérationelle.

Ce langage servira de support aux systèmes de types décrits dans les chapitres 6, 7 et 8. La traduction depuis C sera explicitée dans le chapitre 9.

## 5.1 Syntaxe

La figure 5.1 définit un langage impératif. On suppose qu'on peut compiler un programme écrit en C vers ce langage.

Un programme est un triplet  $P = (\vec{f}, \vec{v}, b)^1$  constitué d'un ensemble de fonctions, d'un ensemble de variables et d'un bloc d'instructions. Ce bloc sera exécuté au lancement du programme; il peut par exemple contenir le code d'initialisation des variables globales et l'appel à la fonction principale.

Les différences principales avec C sont les suivantes :

- le flôt de contrôle est simplifié : les seules constructions sont l'alternative, la boucle infinie et le saut en avant.
- les expressions sont sans effets de bords. En particulier, leur évaluation peut être faite sans modifier l'environnement.
- les opérateurs pour entiers et les flottants sont différenciées.

## 5.2 Sémantique

Dans cette section, nous définissons une sémantique pour ce langage impératif; elle pourra servir à l'implantation d'un interpréteur et à raisonner de manière formelle sur les programmes.

1. dans tout ce chapitre on utilise la notation des vecteur pour les collections ordonnées :  $\vec{f} = (f_1, f_2, ..., f_n)$ ,  $\vec{v} = (v_1, v_2, ..., v_p)$  (leur cardinalités ne sont pas forcément égales).

Fonctions

Ajouter l'arithmétique des pointeur + types

expliquer pourquo un while expr ne suffit pas

Programmes	$P ::= (\vec{f}, \vec{v}, b)$	Fonctions, globales, initialiseur
	e ::= lv	Left-value
	op <i>e</i>	Opération unaire
Expressions	e op e	Opération binaire
	c	Constante
	& lv	Pointeur sur donnée
	& <i>f</i>	Pointeur sur fonction
<b>Q</b>	c ::= n	Entier
Constantes	<i>f</i>	Flottant
	NIL	Pointeur nul
	op ::= +,-,×,/	Arithmétique entière
	+.,,×.,/.	Arithmétique flottante
Opérateurs	=,≠,≤,≥,<,>	Comparaisons
	&, ,^,~	Opérateurs bit à bit
	&&,  ,!	Opérateurs logiques
	<b>│</b> ≪,≫	Décalages
	lv ::= var	Variable
Left-values	$\mid lv.champ$	Accès à un champ
	lv[e]	Accès à un tableau
	* <i>e</i>	Déréférencement
Blocs	b ::= i; b	Séquence
	$\mid \; \epsilon$	Bloc vide
	$i ::= lv \leftarrow e$	Affectation
	$  lv \leftarrow funexp(args) $	Appel de fonction
	funexp(args)	Appel de procédure
To other otions	$\mid \ \operatorname{DECL}\ nom\{b\}$	Déclaration
Instructions	$\mid \ \text{If}(e)\{b\} \text{ELSE}\{b\}$	Alternative
	$\mid \ \operatorname{Do}\{b\}\operatorname{With}\ label$	: Nommage de bloc
	Gото label	Saut en avant
	WHILE(1) $\{b\}$	Boucle infinie
	Return e	Retour de fonction

FIGURE 5.1 – Syntaxe d'un langage impératif

5.2. SÉMANTIQUE 31

Mathématiquement, cela consiste en la définition d'une relation de transition  $\rightarrow$  entre états de l'interpréteur.

Un état est constitué d'une part d'un point de contrôle dans le programme (section 5.2.1, et d'autre part de l'état  $\sigma$  de la mémoire (section 5.2.2).

## 5.2.1 Graphe de flot de contrôle



Dans la syntaxe ci-dessus, on peut classifier les instructions en deux familles : celles qui définissent le flot de contrôle (IF( $\cdot$ ) {  $\cdot$  } ELSE {  $\cdot$  }, DO{  $\cdot$  }WITH  $\cdot$ :, GOTO  $\cdot$ , WHILE(1){ $\cdot$ }) et celles qui définissent le flot de données. Une première transformation va transformer chaque fonction en son graphe de flot de contrôle, défini comme suit :

- les nœuds sont des points de contrôle, qui représentent par exemple l'adresse mémoire de l'instruction qui vient d'être exécutée.
- les arêtes sont soit des instructions "de données" (affectation, appel de fonction, déclaration), soit des conditions (ie une expression).

```
int32 gcd(int32 a, int32 b) {
                                               if (a == 0) {
                                                 !return = b_int32;
int gcd(int a, int b)
                                                 goto lbl0;
{
    if (a == 0) {
                                               while (1) {
        return b;
                                                   if (b == 0) {
    }
                                                       goto lbl1;
    while (b != 0) {
        if (a > b) {
                                                   if (a > b) {
            a = a - b;
                                                        a = a - b;
        } else {
                                                   } else {
            b = b - a;
                                                        b = b - a;
                                                   }
        }
                                               }
    }
}
                                               lbl1:
                                               1b10:
                                          }
XXX
```

Intuitivement, on peut "passer" d'un état à un autre soit en passant par une arête "condition" qui s'évalue à une valeur "vrai", soit en appliquant les effets de bord d'une arête "instruction".

Dans la suite, on suppose qu'on a à notre disposition un ensemble de jugements :  $\langle l, instr, l' \rangle$  qui signifie qu'on peut passer du point l au point l' en effectuant l'instruction instr.

## 5.2.2 État mémoire

L'interpréteur défini ici manipule des valeurs :

On note l'ensemble des valeurs VAL.

**Définition 5.1 (État mémoire)** L'interpréteur possède une mémoire, indexée par un ensemble d'adresses noté ADDR. Un état mémoire σ est une fonction partielle de ADDR vers VAL.

l faut une opéraion genre from-Bytes

rtes

'ile d'appels

**Définition 5.2 (Fonction de transition)** La sémantique concrète que nous définissons ici est constituée de jugements logiques. Le jugement principal est une relation de transition  $\rightarrow$  entre états de l'interpréteur : il sera donc noté  $\Gamma \vdash (l, \sigma) \rightarrow (l', \sigma')$ .

#### 5.2.3 Jugements

La sémantique concrète repose sur des jugements logiques et des règles d'inférences, de la forme :

$$\frac{P_1 \quad \dots \quad P_n}{C}$$
 (Nom)

Les  $P_i$  sont les prémisses, et C la conclusion. Cette règle s'interprète de la manière suivante : si les  $P_i$  sont prouvées, alors C est prouvée.

Certaines règles n'ont pas de prémisse : on parle alors d'axiome.

$$\frac{1}{A}$$
 (Ax)

Compte-tenu de la structure des règles, la preuve d'un jugement pourra donc être vue sous la forme d'un arbre :

$$\frac{\overline{A_{1}}^{(R3)} \quad \overline{A_{2}}^{(R4)}}{B_{1}}^{(R2)} \quad \frac{\overline{A_{3}}^{(R6)}}{B_{2}}^{(R5)} \\
\underline{C}^{(R1)}$$

5.2. SÉMANTIQUE 33

#### 5.2.4 Sémantique des left-values

La mémoire est organisée en adresses, mais pourtant dans le programme cette notion n'est pas directement visible. Les accès sont réalisés à travers des "left values". Dans le langage C, elles correspondent aux constructions qui peuvent se retrouver à gauche du signe "=" dans une affectation.

**Définition 5.3 (Correspondance left-values / adresses)** Sous un environnement  $\Gamma$  et un état mémoire  $\sigma$ , une left-value peut correspondre à une adresse a. Ceci sera noté  $\Gamma, \sigma \vdash lv \rightsquigarrow a$ .

$$\frac{(v,a) \in \sigma}{\Gamma, \sigma \vdash v \leadsto a} \text{ (EVAL-LV-VAR)} \qquad \qquad \frac{\Gamma, \sigma \vdash e \Rightarrow \&a}{\Gamma, \sigma \vdash *e \leadsto a} \text{ (EVAL-LV-DEREF)}$$
 
$$\frac{\Gamma, \sigma \vdash lv \leadsto a}{\Gamma, \sigma \vdash lv \mathrel{f} \leadsto a + f} \text{ (EVAL-LV-FIELD)} \qquad \frac{\Gamma, \sigma \vdash lv \leadsto a}{\Gamma, \sigma \vdash lv \mathrel{f} \bowtie a + n} \text{ (EVAL-LV-ARRAY)}$$

## 5.2.5 Sémantique des expressions

Les expressions sont les constructions syntaxiques de base du langage. Étant donné un environnement et un état mémoire, on peut leur associer une valeur.

Par exemple, dans l'environnement qui à la variable x associe l'adresse a et dans l'état mémoire qui à l'adresse a associe la valeur 2, l'expression x + 3 s'évalue en 5.

**Définition 5.4 (Évaluation d'une expression)** Sous un environnement  $\Gamma$  et un état mémoire  $\sigma$ , une left-value peut produire une valeur v. Ceci sera noté  $\Gamma, \sigma \vdash e \Rightarrow v$ .

Dans le cas où l'expression est une constante, c'est directement le résultat.

$$\frac{}{\Gamma, \sigma \vdash c \Rightarrow c} \text{ (EVAL-CST)}$$

Si l'expression est une left-value, on établit à quelle adresse elle correspond et on récupère dans l'état mémoire à quelle valeur celle-ci correspond.

$$\frac{\Gamma, \sigma \vdash lv \leadsto a \qquad (a, v) \in \sigma}{\Gamma, \sigma \vdash lv \Rightarrow v}$$
(EVAL-LV)

En ce qui concerne les opérations (unaires ou binaires), on commence par évaluer les opérandes. Le résultat est l'opération "concrète" sur les valeurs, notée  $\widehat{op}$ . Par exemple, pour la construction syntaxique +, on utilise l'addition sur les valeurs  $\widehat{+}$  (c'est-à-dire l'addition usuelle).

$$\frac{\Gamma, \sigma \vdash e \Rightarrow v}{\Gamma, \sigma \vdash \text{op } e \Rightarrow \widehat{\text{op}} \ v} \text{ (EVAL-UNOP)} \qquad \frac{\Gamma, \sigma \vdash e_1 \Rightarrow v_1 \qquad \Gamma, \sigma \vdash e_2 \Rightarrow v_2}{\Gamma, \sigma \vdash e_1 \text{ op } e_2 \Rightarrow v_1 \ \widehat{\text{op}} \ v_2} \text{ (EVAL-BINOP)}$$

Enfin, les adresses sont aussi des valeurs. Le cas des pointeurs sur fonction est direct puisque toutes les fonctions sont globales; pour le cas des pointeurs sur données on commence par déterminer l'adresse de l'objet pointé depuis l'état mémoire.

$$\frac{\Gamma, \sigma \vdash lv \leadsto a}{\Gamma, \sigma \vdash \&f \Rightarrow \&f} \text{ (EVAL-ADDROFFUN)} \qquad \frac{\Gamma, \sigma \vdash lv \leadsto a}{\Gamma, \sigma \vdash \&lv \Rightarrow \&a} \text{ (EVAL-ADDROF)}$$

## 5.2.6 Sémantique des instructions

La règle la plus simple concerne l'affectation : on peut affecter une expressions à une left value si elles ont le même type.

$$\frac{\langle l, lv \leftarrow e, l' \rangle \qquad \Gamma, \sigma \vdash lv \leadsto a \qquad \Gamma, \sigma \vdash e \Rightarrow v}{\Gamma \vdash (l, \sigma) \rightarrow (l', \sigma[a \mapsto v])}$$
(Instr-Assign)

Déclarer une variable, c'est rendre accessible dans un bloc une variable non initialisée, qui n'est plus accessible par la suite : Si on suppose qu'on peut traverser le bloc interne b sous un  $\sigma$  enrichi d'une nouvelle variable x, on peut donc traverser l'instruction DECL x { b }.

$$(l, \text{DECL } x\{b\}, l') \qquad \langle l_b, b, l'_b \rangle$$

$$\sigma' = \sigma \oplus \{x \to \top\} \qquad \Gamma \vdash (l_b, \sigma', s) \to (l'_b, \sigma'')$$

$$\Gamma \vdash (l, \sigma) \to (l', \sigma'' \setminus x)$$
(Instr-Decl)
$$(l_b) \qquad b \qquad (l'_b) \qquad (l'_$$

TODO pour :

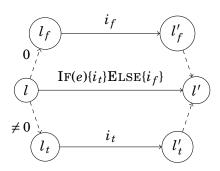
$$\begin{split} \langle l, lv \leftarrow fe(\vec{e}), l' \rangle \\ \sigma \vdash fe \Rightarrow f & \Gamma, \sigma \vdash \vec{e} \Rightarrow \vec{v} & \sigma' = \sigma \oplus \{args(f) = \vec{v}\} \oplus \{!ret \rightarrow \top\} \\ \frac{\Gamma \vdash (Entry(f), \sigma') \rightarrow (Exit(f), \sigma'') & \Gamma, \sigma'' \vdash !ret \Rightarrow v_{ret} & \Gamma, \sigma'' \vdash lv \leadsto a}{\Gamma \vdash (l, \sigma) \rightarrow (l', \sigma'' \setminus (args(f) \cup \{!ret\}) \oplus \{a \rightarrow v_{ret}\}, ?)} \end{split}$$
 (Instr-Fcall)

finir  $\sigma \vdash f \rho \Rightarrow f$ 

## 5.2.7 Sémantique des conditions

On utilise un encodage similaire à la déclaration. Tout d'abord, on évalue la condition dans un contexte  $\sigma$ . Si elle s'évalue en un entier non nul, et qu'une transition à travers le bloc  $i_t$  est possible, alors on peut faire passer à travers le "IF".

5.2. SÉMANTIQUE



$$\begin{split} &\langle l, \text{IF}(e)\{i_t\} \text{ELSE}\{i_f\}, l'\rangle \\ &\Gamma, \sigma \vdash e \Rightarrow n \quad n \neq 0 \\ &\frac{\langle l_i, i_t, l'_i\rangle \quad \Gamma \vdash (l_i, \sigma) \rightarrow (l'_i, \sigma')}{\Gamma \vdash (l, \sigma) \rightarrow (l', \sigma')} \text{ (IF-TRUE)} \\ &\frac{\langle l, \text{IF}(e)\{i_t\} \text{ELSE}\{i_f\}, l'\rangle}{\Gamma, \sigma \vdash e \Rightarrow 0} \\ &\frac{\langle l_i, i_f, l'_i\rangle \quad \Gamma \vdash (l_i, \sigma) \rightarrow (l'_i, \sigma')}{\Gamma \vdash (l, \sigma) \rightarrow (l', \sigma')} \text{ (IF-FALSE)} \end{split}$$

# SÉMANTIQUE STATIQUE

Ici nous enrichissons le langage défini dans le chapitre 5 d'un système de types. Celui-ci permet d'obtenir plus de garanties que celui de C tel que décrit dans [ISO99].

Il permet le polymorphisme sur les types pointeurs, permettant par exemple de typer :

$$\vdash$$
 memcpy:  $\forall a.(a^*, a^*, INT) \rightarrow VOID$ 

## 6.1 Règles de typage

## **6.1.1** Types

Dans cette section, on définit la notion de programme bien typé. L'analyse par typage permet de vérifier qu'à chaque expression on peut associer un type, et ce de manière cohérente entre plusieurs utilisations d'une variable.

Les types des valeurs sont :

	$\tau ::= \text{Int}, \text{Float}, \text{Void}$	Constante
	a	Variable
Types	$  (\tau_1, \ldots, \tau_n) \to \tau_r$	Fonction
	[τ]	Tableau
	τ*	Pointeur
	$  \{f_1:\tau_1,\ldots,f_n:\tau_n\}$	Structure

L'ensemble des types possibles (défini inductivement ci-dessus) sera noté TYP, et l'ensemble des variables de type par VARTYP.

## 6.1.2 Schémas de type

On va associer à chaque variable globale un type. Mais faire de même pourrait être trop restrictif. En effet, une fonction comme memcpy peut être utilisée pour copier des tableaux d'entiers, mais aussi de flottants. On va donc associer un schéma de types à chaque fonction.

Schémas 
$$\sigma ::= \forall \vec{a}. au$$

Un schéma de types correspond à un ensemble de types. Prenons l'exemple de la fonction identité : elle a pour schéma de types  $\forall a.a \rightarrow a$ , ce qui signifie que pour chaque type  $\tau$ , on peut l'utiliser avec le type  $\tau \rightarrow \tau$ . Plus précisément, cela veut dire que puisque a est quantifiée, on peut le substituer par n'importe quel autre type.

**Définition 6.1 (Substitution)** Une substitution est une fonction partielle de VARTYP dans TYP. Elle sera notée par exemple  $s = \{a \mapsto INT, b \mapsto (FLOAT \to INT)\}.$ 

Le domaine de définition d'une substition est noté Dom(s).

On définit aussi l'application d'une substitution sur un type quelconque : si s est une substitution,  $\overline{s}$  est son extension définie par :

$$\overline{s}(a) = s(a) \qquad \qquad si \ a \ est \ une \ variable$$
 
$$\overline{s}(c) = c \qquad \qquad si \ c \ est \ une \ constante$$
 
$$\overline{s}([\tau]) = [\overline{s}(\tau)]$$
 
$$\overline{s}(\tau*) = \overline{s}(\tau)*$$
 
$$\overline{s}(\tau_1, \dots, \tau_n) \to \tau_r = (\overline{s}(\tau_1), \dots, \overline{s}(\tau_n)) \to \overline{s}(\tau_r)$$
 
$$\overline{s}(\{f_1: \tau_1, \dots, f_n: \tau_n\}) = \{f_1: \overline{s}(\tau_1), \dots, f_n: \overline{s}(\tau_n)\}$$

Par souci de simplicité, on notera s pour  $\bar{s}$ .

**Définition 6.2 (Instanciation)** Un schéma de types  $\sigma = \forall \vec{a}.\tau$  peut être instancié en un type  $\mu$  s'il existe une substition s telle que :

- $Dom(s) \subseteq \vec{a}$
- $s(\tau) = \mu$

*On note alors*  $\mu \leq \sigma$ .

**Définition 6.3 (Variables libres)** Les variables libres d'un type sont l'ensemble des variables de types qui apparaissent dans celui-ci :

$$Free Vars(a) = \emptyset \qquad \qquad si \ a \ est \ une \ variable$$
 
$$Free Vars(c) = \emptyset \qquad \qquad si \ c \ est \ une \ constante$$
 
$$Free Vars([\tau]) = Free Vars(\tau)$$
 
$$Free Vars(\tau*) = Free Vars(\tau)$$
 
$$Free Vars((\tau_1, \dots, \tau_n) \to \tau_r) = Free Vars(\tau_1) \cup \dots \cup Free Vars(\tau_n) \cup Free Vars(\tau_r)$$
 
$$Free Vars(\{f_1: \tau_1, \dots, f_n: \tau_n\}) = Free Vars(\tau_1) \cup \dots \cup Free Vars(\tau_n)$$

On étend cette définition aux schémas de types :

$$FreeVars(\forall \vec{a}.\tau) = FreeVars(\tau) - \vec{a}$$

ainsi qu'aux contextes de typage :

$$FreeVars(\epsilon) = \emptyset$$
 
$$FreeVars(\Gamma, x : \tau) = FreeVars(\Gamma) \cup FreeVars(\tau)$$
 
$$FreeVars(\Gamma, f : \sigma) = FreeVars(\Gamma) \cup FreeVars(\sigma)$$

**Définition 6.4 (Généralisation)** La généralisation consiste à construire un schéma de type à partir d'un type, en quantifiant sur les variables libres :

$$Gen(\tau, \Gamma) = \forall \vec{a}.\tau \quad où \quad \vec{a} = FreeVars(\tau) - FreeVars(\Gamma)$$

En associant un schéma de type  $\sigma$  à une fonction f, on indique que la fonction pourra être utilisée avec tout type  $\tau$  qui est une instanciation de  $\sigma$ .

#### 6.1.3 Environnements de typage

Chaque jugement de typage est effectué dans un environnement de typage  $\Gamma$  particulier, qui contient le contexte nécessaire : ici, le type des fonctions et variables du programme.

	$\Gamma ::= (\Gamma_{fun}, \Gamma_{var})$	Fonctions, variables
Environnements	$\Gamma_{fun} ::= \epsilon$ $\mid \Gamma_{fun}, f : \sigma$	Environnement vide Ajout d'une fonction
	$\Gamma_{var} ::= \epsilon$ $\mid \Gamma_{var}, v : \tau$	Environnement vide Ajout d'une variable

Lorsque ce n'est pas ambigü, si  $\Gamma = (\Gamma_{fun}, \Gamma_{var})$  on notera les extensions d'environnement  $\Gamma, f : \sigma$  pour  $((\Gamma_{fun}, f : \sigma), \Gamma_{var})$  et  $\Gamma, x : \tau$  pour  $(\Gamma_{fun}, (\Gamma_{var}, x : \tau))$ . De même, on notera  $(f, \sigma) \in \Gamma$  si  $(f, \sigma) \in \Gamma_{fun}$ , ou  $(x, \tau) \in \Gamma$  si  $(x, \tau) \in \Gamma_{var}$ .

## 6.1.4 Jugements de typage

Un des principes du typage est d'associer à chaque expression un type, qui décrit le genre des valeurs produites par l'évaluation de cette fonction.

**Définition 6.5 (Jugement de typage)** Un jugement de typage est de la forme  $\Gamma \vdash e : \tau$  et se lit "sous  $\Gamma$ , e est typable en  $\tau$ ".

Les instructions et blocs, au contraire, n'ont pas de type.

**Définition 6.6 (Bloc bien typé)** On note  $\Gamma \vdash i$  pour "sous  $\Gamma$ , i est bien typé", c'est à dire que ces sous expressions sont typables en accord avec le flot de données (par exemple, pour que l'instruction  $lv \leftarrow e$  soit bien typée sous  $\Gamma$ , il faut que les types de lv et de e puissent avoir le même type sous  $\Gamma$ ).

Le cas des fonctions est particulier puisque celles-ci ont un schéma de types qui leur est associé.

**Définition 6.7 (Fonction bien typée)** On note  $\Gamma \vdash f : \sigma$  le fait qu'une fonction f est typable en un schéma  $\sigma$  dans  $\Gamma$ .

Enfin, la notion de programme bien typé est intrinsèque : elle se fait indépendemment d'un environnement externe.

**Définition 6.8 (Programme bien typé)** Un programme P est bien typé s'il existe un environnement  $\Gamma$  permettant de bien typer toutes les composantes (fonctions, globales et bloc d'initialisation) d'un programme. On notera alors  $\vdash P$ .

## 6.1.5 Programme

Au niveau global, un programme P est bien typé (noté  $\vdash P$ ) s'il existe un environnement  $\Gamma = (\vec{\sigma}, \vec{\tau})$  permettant de typer ses composantes (les fonctions, les globales et le bloc d'initialisation).

$$\frac{(\vec{\sigma}, \vec{\tau}) \vdash \vec{f} : \vec{\sigma} \qquad (\vec{\sigma}, \vec{\tau}) \vdash \vec{x} : \vec{t} \qquad (\vec{\sigma}, \vec{\tau}) \vdash b}{\vdash (\vec{f}, \vec{x}, b)}$$
(Prog)

#### 6.1.6 Flot de contrôle

Les règles suivantes permettent de définir les jugements  $\Gamma \vdash i$ . De manière générale, les instructions sont bien typées si leurs sous-instructions sont bien typées.

$$\frac{\Gamma \vdash s}{\Gamma \vdash \epsilon} \text{ (PASS)} \qquad \frac{\Gamma \vdash s}{\Gamma \vdash s; b} \text{ (SEQ)} \qquad \frac{\Gamma \vdash b}{\Gamma \vdash \text{WHILE}(1)\{b\}} \text{ (WHILE)} \qquad \frac{\Gamma \vdash b}{\Gamma \vdash \text{DO}\{b\}\text{WITH } l:} \text{ (DOWITH)}$$

Dans le cas de la conditionnelle, il est en plus nécessaire de vérifier que la condition est un entier.

$$\frac{\Gamma \vdash e : \text{INT} \qquad \Gamma \vdash i_t \qquad \Gamma \vdash i_f}{\Gamma \vdash \text{IF}(e)\{i_t\} \text{ELSE}\{i_f\}} \text{ (IF)}$$

#### 6.1.7 Left values

On associe à chaque left-value un type, qui est aussi le type des valeurs que celle-ci peut contenir. Le cas des variables est direct : si un couple (variable, type) est dans l'environnement de typage, la variable possède ce type.

$$\frac{(v,\tau)\in\Gamma}{\Gamma\vdash v:\tau}$$
 (LV-VAR)

Si une expression a un type pointeur, en la déréférençant on obtient une valeur du type pointé.

$$\frac{\Gamma \vdash e : \tau *}{\Gamma \vdash *e : \tau} \text{ (LV-DEREF)}$$

accès à un élément d'un type composite

$$\frac{\Gamma \vdash lv : \tau_s \qquad (f, \tau_f) \in \tau_s}{\Gamma \vdash lv . f : \tau_f} \text{(LV-FIELD)} \qquad \frac{\Gamma \vdash lv : [\tau] \qquad \Gamma \vdash e : \text{INT}}{\Gamma \vdash lv [e] : \tau} \text{(LV-Array)}$$

## 6.1.8 Expressions

Les constantes ont leurs types habituels. Notons que le pointeur nul (NIL) a un type polymorphe.

$$\frac{}{\Gamma \vdash n : \text{INT}} \text{(Const-Int)} \qquad \frac{}{\Gamma \vdash f : \text{Float}} \text{(Const-Float)} \qquad \frac{}{\Gamma \vdash \text{Nil} : \tau *} \text{(Const-Nil)}$$

Un certain nombre d'opérations est possible sur le type INT.

$$\frac{\text{op} \in \{+,-,\times,/,\&,|,^{\wedge},\&\&,||,\ll,\gg\} \qquad \Gamma \vdash e_1 : \text{INT} \qquad \Gamma \vdash e_2 : \text{INT}}{\Gamma \vdash e_1 \text{ op } e_2 : \text{INT}} \text{ (OP-INT)}$$

De même sur Float.

$$\frac{\text{op} \in \{+,,-,\times,/,\} \qquad \Gamma \vdash e_1 : \text{FLOAT} \qquad \Gamma \vdash e_2 : \text{FLOAT}}{\Gamma \vdash e_1 \text{ op } e_2 : \text{FLOAT}} \text{ (OP-FLOAT)}$$

Les opérateurs de comparaison peuvent s'appliquer à deux opérandes de types "comparables". On introduit donc un jugement COMPARABLE( $\tau$ ) qui est vrai pour les types INT, FLOAT et pointeurs. Les comparaisons renvoient alors un INT.

$$\frac{\tau \in \{\text{Int}, \text{Float}\}}{\text{Comparable}(\tau)} \text{(Cmp-Num)} \qquad \frac{}{\text{Comparable}(\tau*)} \text{(Cmp-Ptr)}$$
 
$$\frac{\text{op} \in \{=, \neq, \leq, \geq, <, >\} \qquad \Gamma \vdash e_1 : \tau \qquad \Gamma \vdash e_2 : \tau \qquad \text{Comparable}(\tau)}{\Gamma \vdash e_1 \text{ op } e_2 : \text{Int}} \text{(Op-Cmp)}$$

L'opérateur unaire "-" peut être appliqué à un INT ou à un FLOAT.

$$\frac{\tau \in \{\text{INT}, \text{FLOAT}\} \qquad \Gamma \vdash e : \tau}{\Gamma \vdash -e : \tau} \text{ (Unop-Minus)}$$

Les opérateurs de négation unaires, en revanche, ne s'appliquent qu'aux entiers.

$$\frac{\text{op} \in \{\sim,!\} \qquad \Gamma \vdash e : \text{INT}}{\Gamma \vdash \text{op } e : \text{INT}} \text{ (Unop-Not)}$$

On peut prendre l'adresse d'une left-value, et obtenir un pointeur vers celle-ci. Le type du résultat est un type pointeur vers le type de base.

$$\frac{\Gamma \vdash lv : \tau}{\Gamma \vdash \&lv : \tau *} \text{(ADDROF)}$$

La règle concernant les pointeurs sur fonction est similaire, à ceci près qu'une fonction a un schéma de type, qu'il faut instancier afin d'obtenir un type pointeur.

$$\frac{\Gamma \vdash f : \sigma \qquad \tau \leq \sigma}{\Gamma \vdash \& f : \tau} \text{ (AddrOfFun)}$$

#### 6.1.9 Fonctions

Pour typer une fonction, on commence par ajouter ses paramètres dans l'environnement de typage, et on type la définition de la fonction. Le type résultant est généralisé.

Vérifier qu'il n'y a les de problème entre polymorchisme et mutacilité

$$\frac{\Gamma' = \Gamma \oplus \{args(f) = \vec{\tau}\} \qquad \Gamma' \vdash body(f) \qquad \Gamma' \vdash !ret : \tau_r}{\Gamma \vdash f : Gen(\vec{\tau} \to \tau_r, \Gamma)} \text{ (Fun)}$$

#### 6.1.10 Instructions

Pour typer une déclaration, il suffit de rajouter la variable avec n'importe quel type dans l'environnement de typage.

$$\frac{\Gamma, x : \tau \vdash b}{\Gamma \vdash \text{DECL } x\{b\}} \text{(DECL)}$$

Une affectation est bien typée si elle faite entre une left-value et une expression de même type.

$$\frac{\Gamma \vdash lv : \tau \qquad \Gamma \vdash e : \tau}{\Gamma \vdash lv \leftarrow e}$$
 (Assign)

6.2. LIMITATIONS 43



$$\frac{\Gamma \vdash lv : \tau_{ret} \qquad \Gamma \vdash fe : \sigma \qquad \Gamma \vdash \vec{e} : \vec{\tau} \qquad (\vec{\tau} \to \tau_r) \leq \sigma}{\Gamma \vdash lv \leftarrow fe(\vec{e})}$$
(FCALL)

## **6.2** Limitations

## 6.2.1 Programmes non typables

## 6.2.2 Incohérences

## ANALYSE DE PROVENANCE DES POINTEURS

Dans le chapitre 6, nous avons vu comment ajouter un système de types forts statiques à un langage impératif. Ici, nous étendons ce système afin de lui ajouter des *qualificateurs de type* qui décrivent l'origine des données. Ils permettent de restreindre certaines opérations sensibles à des expressions dont la valeur est sûre.

## 7.1 Éditions et ajouts

Qualificateurs	$q ::=  ext{Kernel}$	Donnée noyau (sûre)
	User	Donnée utilisateur (non sûre)
Ensuite,		
Types	au ::=  au q *	Pointeur qualifié
	l	Reste inchangé
voire:		
Environnements		$\Gamma ::= \epsilon$
		$\mid \Gamma, x : \tau \mid q$
Règle de sûreté du déréfé	rencement	

$$\frac{\Gamma \vdash e : \tau \text{ Kernel*}}{\Gamma \vdash *e : \tau} \text{ (Lv-Deref-Kernel)}$$

## 7.2 Propriété d'isolation mémoire

Le déréférencement d'un pointeur dont la valeur est contrôlée par l'utilisateur ne peut se faire qu'à travers une fonction qui vérifie la sûreté de celui-ci.

# ANALYSE DE TERMINAISON DES CHAÎNES C

Dans ce chapitre, nous présentons une autre extension au système de types du chapitre 6, similaire à celle du chapitre 7. Il s'agit cette fois-ci de détecter les pointeurs sur caractères (char \*) qui sont terminés par un caractère NUL et donc une chaîne C correcte. La bibliothèque C propose quantité de fonctions manipulant ces chaînes et appeler une fonction comme strcpy sur un pointeur quelconque est un problème de sécurité que nous cherchons à détecter.

## 8.1 But

Le langage C ne fournit pas directement de type "chaîne de caractère". C'est au programmeur de les gérer via des pointeurs sur caractère (char \*).

En théorie le programmeur est libre de choisir une représentation : des chaînes préfixées par la longueur, une structure contenant la taille et un pointeur vers les données, ou encore une chaîne avec un terminateur comme 0.

Néanmoins c'est ce dernier style qui est le plus idiomatique : par exemple, les littéraux de chaîne ("comme ceci") ajoutent un octet nul à la fin. De plus, le standard décrit dans la bibliothèque d'exécution de nombreuses fonctions destinées à les manipuler — c'est le fichier <string.h> ([ISO99] section 7.21).

Ainsi la fonction strcpy a pour protoype:

```
char *strcpy(char *dest, const char *src);
```

Elle réalise la copie de la chaîne pointée par src à l'endroit pointé par dest. Pour détecter la fin de la chaîne, cette fonction parcourt la mémoire jusqu'à trouver un caractère nul. Une implémentation naïve pourrait être :

```
char *strcpy(char *dest, const char *src)
{
   int i;
   for(i=0;src[i]!=0;i++) {
     dest[i] = src[i];
   }
   return dest;
}
```

La copie n'est arrêtée que lorsqu'un 0 est lu. Autrement dit, si quelqu'un contrôle la valeur pointée par src, il pourra écraser autant de données qu'il le désire. On est dans le cas d'école du débordement de tampon sur la pile tel que décrit dans [One96]. Considérons la fonction suivante :

```
void f(char *src)
{
    char buf[100];
    strcpy(buf, src);
}
```

Si le pointeur src pointe sur une chaîne de longueur supérieure à 100 (ou une zone mémoire qui n'est pas une chaîne et ne contient pas de 0), les valeurs placées sur la pile juste avant buf (à une adresse supérieure) seront écrasées. Avec les conventions d'appel habituelles, il s'agit de l'adresse de retour de la fonction. Un attaquant pourra donc détourner le flot d'exécution du programme.

Pour éviter ces cas de fonctions vulnérables, on peut introduire une distinction entre les pointeurs char \* classiques (représentant l'adresse d'un caractère par exemple) et les pointeurs sur une chaîne terminée par un caractère nul.

Dans certaines bases de code (la plus célèbre étant celle de Microsoft), une convention syntaxique est utilisée : les pointeurs vers des chaînes terminées par 0 ont un nom qui commence par sz, comme "szTitle". C'est pourquoi nous appellerons ce qualificateur de type sz.

## 8.2 Approche

Cette propriété est un peu différente de la séparation entre espace utilisateur et espace noyau modélisée dans le chapitre 7 : autant un pointeur reste contrôlé par l'utilisateur (ou sûr) toute sa vie, autant le fait d'être terminé par un octet nul dépend de l'ensemble de l'état mémoire. Il y a deux problèmes principaux à considérer.

D'une part, l'*aliasing* rend l'analyse difficile : si p et q pointent tous les deux vers une même zone mémoire, le fait de modifier l'un peut modifier l'autre. D'autre part, ce n'est pas parce qu'une fonction maintient l'invariant de terminaison, qu'elle le maintient à chaque instruction.

On peut résoudre en partie le problème d'aliasing en étant très conservateur, c'est à dire en sous-approximant l'ensemble des chaînes du programme (on traitera une chaîne légitime comme une chaîne non terminée, interdisant par excès de zèle les fonctions comme strcpy).

Le second problème est plus délicat puisqu'il casse l'hypothèse habituelle que chaque variable conserve le même type au long de sa vie. Plusieurs techniques sont possibles pour contourner ce problème : la première est d'être encore une fois conservateur et d'interdire ces constructions (on ne pourrait alors analyser que les programmes ne manipulant les chaînes qu'à travers les fonctions de la bibliothèque standard). Une autre est d'insérer des annotations permettant de s'affranchir localement du système de types. Enfin, il est possible d'utiliser un système de types où les variables ont en plus d'un type, un automate d'états possible dépendant de la position dans le programme : c'est le concept de *typestates*[SY86].

## **8.3** Annotation de string.h

Une première étape est d'annoter l'ensemble des fonctions manipulant les chaînes de caractères.

## 8.3.1 Fonctions de copie

```
memcpy
void *memcpy(void *dest, const void *src, size_t n);
memmove
void *memmove(void *dest, const void *src, size_t n);
strcpy
char *strcpy(char *dest, const char *src);
strncpy
char *strncpy(char *dest, const char *src, size_t n);
8.3.2 Fonctions de concaténation
strcat
char *strcat(char *dest, const char *src);
strncat
char *strncat(char *dest, const char *src, size_t n);
8.3.3 Fonctions de comparaison
memcmp
int memcmp(const void *s1, const void *s2, size_t n);
strcmp
int strcmp(const char *s1, const char *s2);
strncmp
int strncmp(const char *s1, const char *s2, size_t n);
strcoll
```

int strcoll(const char \*s1, const char \*s2);

strlen

size\_t strlen(const char \*s);

```
strxfrm
size_t strxfrm(char *dest, const char *src, size_t n);
8.3.4 Fonctions de recherche
memchr
void *memchr(const void *s, int c, size_t n);
strchr
char *strchr(const char *s, int c);
strcspn
size_t strcspn(const char *s, const char *reject);
strpbrk
char *strpbrk(const char *s, const char *accept);
strrchr
char *strrchr(const char *s, int c);
strspn
size_t strspn(const char *s, const char *accept);
strstr
char *strstr(const char *haystack, const char *needle);
strtok
char *strtok(char *str, const char *delim);
8.3.5 Fonctions diverses
memset
void *memset(void *s, int c, size_t n);
strerror
char *strerror(int errnum);
```

- 8.4 Typage des primitives
- 8.5 Extensions au système de types
- 8.6 Résultats

# Troisième partie Expérimentation

## **IMPLANTATION**

Dans ce chapitre, nous décrivons la mise en œuvre des analyses statiques précédentes. Nous commençons par un tour d'horizon des représentations intermédiaires possibles, avant de décrire celle retenue : Newspeak. La chaîne de compilation est explicitée, partant de C pour aller au langage impératif décrit dans le chapitre 5. Enfin, nous donnons les détails d'un algorithme d'inférence de types à la Hindley-Milner, reposant sur l'unification et le partage de références.

## 9.1 Langages intermédiaires

Le langage C [KR88, ISO99] a été conçu pour être une sorte d'assembleur portable, permettant décrire du code indépendamment de l'architecture sur laquelle il sera compilé. Historiquement, c'est il a permis de créer Unix, et ainsi de nombreux logiciels bas niveau sont écrits en C. En particulier, il existe des compilateurs de C vers les différents langages machine pour à peu près toutes les architectures.

Lors de l'écriture d'un compilateur, on a besoin d'un langage intermédiaire qui fasse l'intermédiaire entre *front-end* et *back-end* (figure 9.1). Depuis ce langage on doit pouvoir exprimer des transformations intermédiaires sur cette représentation (analyses sémantiques, optimisations, etc), mais aussi compiler ce langage vers un langage machine.

L'idée de prendre C comme langage intermédiaire est très séduisante, mais malheureusement sa sémantique est trop complexe et trop peu spécifiée. Il est donc judicieux d'utiliser un langage plus simple à cet effet. Dans de nombreux projets, des sous-ensembles de C ont été définis pour aller dans ce sens.

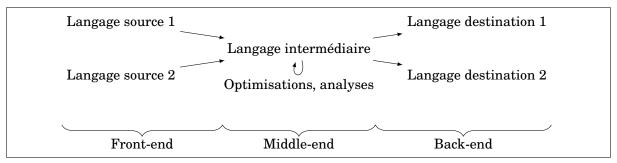


FIGURE 9.1 - Décomposition d'un compilateur : front-ends, middle-end, back-ends

#### Langages

Les premiers candidats sont bien entendu les représentations intermédiaires utilisées dans les compilateurs C. Elles ont l'avantage d'accepter en plus du C standard, les diverses extensions (GNU, Microsoft, Plan9) utilisées par la plupart des logiciels. En particulier, le noyau Linux repose fortement sur les extensions GNU.

GCC utilise une représentation interne nommée GIMPLE[Mer03]. Il s'agit d'une structure d'arbre écrite en C, reposant sur de nombreuses macros afin de cacher les détails d'implémentation pouvant varier entre deux versions de GCC. Cette représentation étant réputée difficile à manipuler, le projet MELT[Sta11] permet de générer une passe de compilation à partir d'un dialecte de Lisp.

**LLVM** [LA04] est un compilateur développé par la communauté puis sponsorisé Apple. À la différence de GCC, sa base de code est écrite en C++. Il utilise une représentation intermédiaire qui peut être manipulée soit sous forme d'une structure de données C++, soit d'un fichier de code-octet compact, soit sous forme textuelle.

Objective Caml [\*1] utilise pour sa génération de code une représentation interne nommée Cmm, disponible dans les sources du compilateur sous le chemin asmcomp/cmm.mli (il s'agit donc d'une structure de données OCaml). Ce langage a l'avantage d'être très restreint, mais malheureusement il n'existe pas directement de traducteur permettant de compiler C vers Cmm.

C- [PJNO97] [�7], dont le nom est inspiré du précédent, est un projet qui visait à unifier les langages intermédiaires utilisés par les compilateurs. L'idée est que si un front-end peut émettre du C- (sous forme de texte), il est possible d'obtenir du code machine efficace. Le compilateur Haskell GHC utilise une représentation intermédiaire très similaire à C-.

Comme le problème de construire une représentation intermédiaire adaptée à une analyse statique n'est pas nouveau, plusieurs projets ont déjà essayé d'y apporter une solution. Puisque qu'ils sont développés en parallèle des compilateurs, le support des extensions est en général moins important dans ces langages.

**CIL** [NMRW02] [ •6] est une représentation en OCaml d'un programme C, développée depuis 2002. Grâce à un mécanisme de greffons, elle permet de prototyper rapidement des analyses statiques de programmes.

**Newspeak** [HL08] est un langage intermédiaire développé par EADS Innovation Works, et qui est spécialisé dans l'analyse de valeurs par interprétation abstraite. Il sera décrit plus en détails dans la section 9.2.

**Compcert** est un projet qui vise à produire un compilateur certifié pour C. C'est à dire que le fait que les transformations conservent la sémantique est prouvé. Il utilise de nombreux langages intermédiaires, dont CIL. Pour le front-end, le langage se nomme Clight[BDL06]. Les passes de middle-end, quant à elles, utilisent Cminor[AB07].

9.2. NEWSPEAK 57

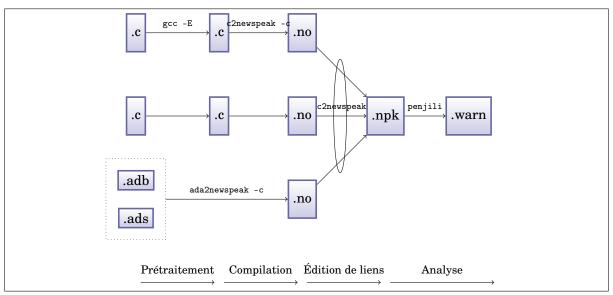


FIGURE 9.2 - Compilation depuis Newspeak

# 9.2 Newspeak



## 9.3 Chaîne de compilation

Mettre à jour la figure

La compilation vers C est faite en trois étapes (figure 9.2) : prétraitement du code source, compilation de C prétraité vers NEWSPEAK, puis compilation de NEWSPEAK vers ce langage.

## 9.3.1 Prétraitement

C2NEWSPEAK travaillant uniquement sur du code prétraité (dans directives de préprocesseur), la première étape consiste donc à faire passer le code par CPP : les macros sont développées, les constantes remplacées par leurs valeurs, les commentaires supprimés, les fichiers d'en-tête inclus, etc.

## 9.3.2 Compilation (levée des ambigüités)

Cette passe est réalisée par l'utilitaire C2NEWSPEAK. L'essentiel de la compilation consiste à mettre à plat les définition de types, et à simplifier le flot de contrôle. C en effet propose de nombreuses constructions ambigües ou redondantes.

Au contraire, NEWSPEAK propose un nombre réduit de constructions. Rappelons que le but de ce langage est de faciliter l'analyse statique : des constructions orthogonales permettent donc d'éviter la duplication de règles sémantique, ou de code lors de l'implémentation d'un analyseur.

Par exemple, plutôt que de fournir une boucle while, une boucle do/while et une boucle for, Newspeak fournit une unique boucle While(1){}. La sortie de boucle est compilée vers un Goto, qui est toujours un saut vers l'avant (similaire à un "break" généralisé).

La sémantique de NEWSPEAK et la traduction de C vers NEWSPEAK sont décrites dans [HL08]. En ce qui concerne l'élimination des sauts vers l'arrière, on peut se référer à [EH94].

#### 9.3.3 Annotations

NEWSPEAK a de nombreux avantages, mais pour une analyse par typage il est trop bas niveau. Par exemple, dans le code suivant

```
struct s {
    int a;
    int b;
};

int main(void)
{
    struct s x;
    int y[10];
    x.b = 1;
    y[1] = 1;
    return 0;
}
```



## 9.3.4 Implantation de l'algorithme de typage

Commençons par étudier le cas du lambda-calcul simplement typé (figure 9.3).

	t ::= x	Variable
	$ \lambda x.t $	Abstraction
	<i>t</i>	Application
Termes	<i>n</i>	Entier
	<i>f</i>	Flottant
	$\mid (t,t)$	Couple
	$\mid \text{ fst } t$	Projection gauche
	$\mid \;                                   $	Projection droite
	$ au ::=  ext{Int}$	Entier
Types	FLOAT	Flottant
J.F.	au  o  au	Fonction
	$  \tau \times \tau$	Produit
Contextes	$\Gamma ::= \epsilon$	Contexte vide
Commission	$  \Gamma, x : \tau$	Extension
	${\Gamma \vdash n : \text{Int}} \text{(Int)} \qquad {\Gamma \vdash f : \text{FL}}$	$\frac{x : \tau \in \Gamma}{\Gamma \vdash x : \tau} \text{ (VAR)}$
Règles	$\frac{\Gamma \vdash f : \tau_1 \to \tau_2 \qquad \Gamma \vdash x : \tau_1}{\Gamma \vdash f x : \tau_2} $ (APP	$\frac{\Gamma, x : \tau_1 \vdash y : \tau_2}{\Gamma \vdash \lambda x. y : \tau_1 \to \tau_2} $ (ABS)
	$\frac{\Gamma \vdash x : \tau_1 \times \tau_2}{\Gamma \vdash \text{fst } x : \tau_1} \text{ (ProJ-G)}$	$\frac{\Gamma \vdash x : \tau_1 \times \tau_2}{\Gamma \vdash \text{snd } x : \tau_2} \text{ (PROJ-D)}$
	$\frac{\Gamma \vdash x : \tau_1}{\Gamma \vdash (x,y) : \tau}$	$\frac{\Gamma \vdash y : \tau_2}{\tau_1 \times \tau_2} $ (TUP)

 ${\tt FIGURE~9.3-Lambda~calcul~simplement~typ\'e~avec~entiers,~flottants~et~couples}$ 

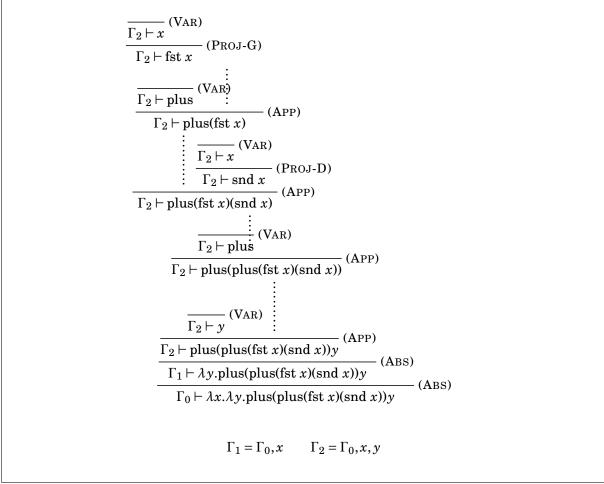


FIGURE 9.4 – Arbre d'inférence : règles à utiliser

Prenons l'exemple de la fonction suivante <sup>1</sup> :

$$f = \lambda x. \lambda y. \text{plus}(\text{plus}(\text{fst}x)(\text{snd}x))y$$

On voit que puisque fst et snd sont appliqués à x, ce doit être un tuple. En outre on additionne ces deux composantes ensemble, donc elles doivent être de type Int (et le résultat aussi). Par le même argument, y doit aussi être de type Int. En conclusion, x est de type Int × Int et y de type Int, donc f est de type Int × Int  $\rightarrow$  Int.

Mais comment faire pour implanter cette analyse? En fait le système de types de la figure 9.3 a une propriété particulièrement intéressante : chaque forme syntaxique (variable, abstraction, etc) est en conclusion exactement d'une règle de typage. Cela permet de toujours savoir quelle règle il faut appliquer.

Partant du terme de conclusion (f), on peut donc en déduire un squelette d'arbre d'inférence (figure  $9.4)^2$ 

<sup>1.</sup> On suppose que plus est une fonction de l'environnement global qui a pour type  $INT \rightarrow INT \rightarrow INT$ .

<sup>2.</sup> Par souci de clarté, les prémisses des applications de (VAR) ne sont pas notées.

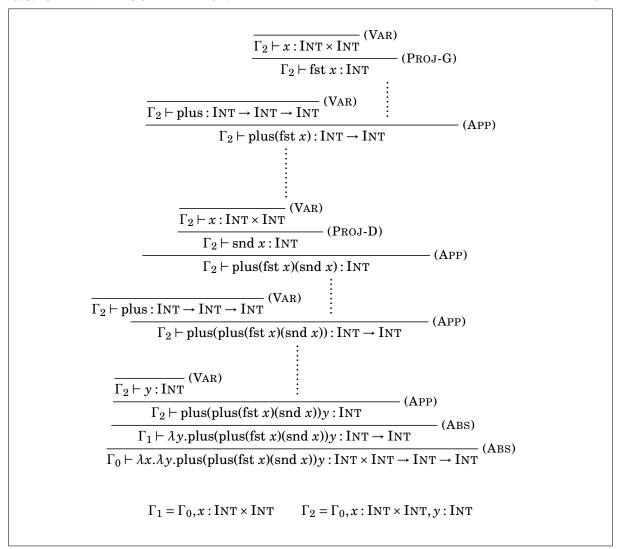


FIGURE 9.5 – Arbre d'inférence complet

Une fois à cette étape, on peut donner un nom à chaque type inconnu :  $\tau_1, \tau_2, \ldots$  L'utilisation qui en est faite permet de générer un ensemble de contraintes d'unification. Par exemple, pour chaque application de la règle (APP) :

$$\frac{\Gamma \vdash \dots : \tau_3 \qquad \Gamma \vdash \dots : \tau_1}{\Gamma \vdash \dots : \tau_2} \text{ (APP)}$$

on doit déduire que  $\tau_3 = \tau_1 \rightarrow \tau_2$ .

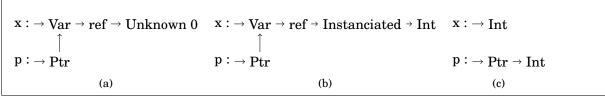


FIGURE 9.6 – Unification par partage

Ce signe = est à prendre comme une contrainte d'égalité : partant d'un ensemble de contraintes de la forme "type avec inconnue = type avec inconnue", on veut obtenir une substitution "inconnue -> type concret".

Pour résoudre ces contraintes, on commence par les simplifier : si  $\tau_a \to \tau_b = \tau_c \to \tau_d$ , alors  $\tau_a = \tau_c$  et  $\tau_b = \tau_d$ . De même si  $\tau_a \times \tau_b = \tau_c \times \tau_d$ . Au contraire, si  $\tau_a \to \tau_b = \tau_c \times \tau_d$ , il est impossible d'unifier les types et il faut abandonner l'inférence de types. D'autre cas sont impossibles, par exemple INT =  $\tau_1 \to \tau_2$  ou INT = FLOAT.

Une fois ces simplifications réalisées, les contraintes restantes sont d'une des formes suivantes :

- $\tau_i = \tau_i$ . Il n'y a rien à faire, cette contrainte peut être supprimée.
- $\tau_i = \tau_j$  avec  $i \neq j$ : toutes les occurrences de  $\tau_j$  dans les autres contraintes peuvent être remplacées par  $\tau_i$ .
- $\tau_i = x$  (ou  $x = \tau_i$ ) où x est un type concret : idem.

ccurs check peut tre?

'est faux

Une fois toutes les substitutions effectuées, on obtient un arbre de typage correct (figure 9.5, donc un programme totalement inféré.

Plutôt que de modifier toutes les occurrences d'un type  $\tau_i$ , on va affecter à  $\tau_i$  la valeur du nouveau type.

L'implémentation de cet algorithme utilise le partage et les références (figure 9.6).

D'abord 9.6a, ensuite 9.6b, et enfin 9.6c.

```
type var_type =
    | Unknown of int
    | Instanciated of ml_type

and const_type =
    | Int_type
    | Float_type

and ml_type =
    | Var_type of var_type ref
    | Const_type of const_type
    | Pair_type of ml_type * ml_type
    | Fun_type of ml_type * ml_type
```



## Le programme C suivant :

```
int x;
int *p = &x;
x = 0;
   est compilé ainsi en Tyspeak :
Decl
  ( "x"
  , Newspeak. Scalar (Newspeak. Int (Newspeak. Signed, 32))
  , ()
  , [ <u>Decl</u>
         ( "p"
         , Newspeak. Scalar Newspeak. Ptr
         , [ <u>Set</u>
                 ( Local "p"
                 , ( <a href="Addr0f">Addr0f</a> (Local "x")
                   , ()
                 , Newspeak. Scalar Newspeak. Ptr
            ; <u>Set</u>
                 ( Local "x"
                 , ( Const (CInt Nat.zero)
                 , Newspeak. Scalar (Newspeak. Int (Newspeak. Signed, 32))
           ]
         )
    ]
```



# ÉTUDE DE CAS: UN PILOTE DE CARTE GRAPHIQUE

#### 10.1 Description du problème



Un système d'exploitation moderne comme GNU/Linux est séparé en deux niveaux de privilèges : le noyau, qui gère directement le matériel, et les applications de l'utilisateur, qui communiquent avec le noyau par l'interface restreinte des *appels système*.

Pour assurer l'isolation, ces deux parties n'ont pas accès aux mêmes zones mémoire (cf. figure 2.5).

Si le code utilisateur tente d'accéder à la mémoire du noyau, une erreur sera déclenchée. En revanche, si cette écriture est faite au sein de l'implantation d'un appel système, il n'y aura pas d'erreur puisque le noyau a accès à toute la mémoire : l'isolation aura donc été brisée.

Pour celui qui implante un appel système, il faut donc empêcher qu'un pointeur passé en paramètre référence le noyau. Autrement dit, il est indispensable de vérifier dynamiquement que la zone dans laquelle pointe le paramètre est accessible par l'appelant[Har88].

Si au contraire un tel pointeur est déréférencé sans vérification (avec \* ou une fonction comme memcpy), le code s'exécutera correctement mais en rendant le système vulnérable, comme le montre la figure 10.1.

Pour éviter cela, le noyau fournit un ensemble de fonctions qui permettent de vérifier dynamiquement la valeur d'un pointeur avant de le déréférencer. Par exemple, dans la figure précédente, la ligne 8 aurait dû être remplacée par :

copy\_from\_user(&value, value\_ptr, sizeof(value));

#### cf annexe A

FIGURE 10.1 – Bug freedesktop.org #29340. Le paramètre data provient de l'espace utilisateur via un appel système. Un appelant malveillant peut se servir de cette fonction pour lire la mémoire du noyau à travers le message d'erreur.

L'analyse présentée ici permet de vérifier automatiquement et statiquement que les pointeurs qui proviennent de l'espace utilisateur ne sont déréférencés qu'à travers une de ces fonctions sûres.

#### 10.2 Principes de l'analyse

Le problème est modélisé de la façon suivante : on associe à chaque variable x un type de données t, ce que l'on note x:t. En plus des types présents dans le langage C, on ajoute une distinction supplémentaire pour les pointeurs. D'une part, les pointeurs "noyau" (de type t \*) sont créés en prenant l'adresse d'un objet présent dans le code source. D'autre part, les pointeurs "utilisateurs" (leur type est noté t user\*) proviennent des interfaces avec l'espace utilisateur.

Il est sûr de déréférencer un pointeur noyau, mais pas un pointeur utilisateur. L'opérateur \* prend donc un t \* en entrée et produit un t.

Pour faire la vérification de type sur le code du programme, on a besoin de quelques règles. Tout d'abord, les types suivent le flot de données. C'est-à-dire que si on trouve dans le code a = b, a et b doivent avoir un type compatible. Ensuite, le qualificateur user est récursif : si on a un pointeur utilisateur sur une structure, tous les champs pointeurs de la structure sont également utilisateur. Enfin, le déréférencement s'applique aux pointeurs noyau seulement : si le code contient l'expression \*x, alors il existe un type t tel que x:t\* et \*x:t.

Appliquons ces règles à l'exemple de la figure 10.1 : on suppose que l'interface avec l'espace utilisateur a été correctement annotée. Cela permet de déduire que data:void user\*. En appliquant la première règle à la ligne 6, on en déduit que info:struct drm\_radeon\_info user\* (comme en C, on peut toujours convertir de et vers un pointeur sur void).

Pour déduire le type de value\_ptr dans la ligne 7, c'est la deuxième règle qu'il faut appliquer : le champ value de la structure est de type uint32\_t \* mais on y accède à travers un pointeur utilisateur, donc value\_ptr:uint32\_t user\*.

À la ligne 8, on peut appliquer la troisième règle : à cause du déréférencement, on en déduit que value\_ptr:t \*, ce qui est une contradiction puisque d'après les lignes précédentes, value\_ptr:uint32\_t user\*.

Si la ligne 3 était remplacée par l'appel à copy\_from\_user, il n'y aurait pas d'erreur de ty-page car cette fonction peut accepter les arguments (uint32\_t \*, uint32\_t user\*, size\_t).

## 10.3 Implantation

Une implantation est en cours. Le code source est d'abord prétraité par gcc -E puis converti en Newspeak [HL08], un langage destiné à l'analyse statique. Ce traducteur peut prendre en entrée tout le langage C, y compris de nombreuses extensions GNU utilisées dans le noyau. En particulier, l'exemple de la figure 10.1 peut être analysé.

À partir de cette représentation du programme et d'un ensemble d'annotations globales, on propage les types dans les sous-expressions jusqu'aux feuilles.

10.4. CONCLUSION 67

Si aucune contradiction n'est trouvée, c'est que le code respecte la propriété d'isolation. Sinon, cela peut signifier que le code n'est pas correct, ou bien que le système de types n'est pas assez expressif pour le code en question.

Le prototype, disponible sur [�8], fera l'objet d'une démonstration.

#### 10.4 Conclusion

Nous avons montré que le problème de la manipulation de pointeurs non sûrs peut être traité avec une technique de typage. Elle est proche des analyses menées dans CQual [FFA99] ou Sparse [�5].

Plusieurs limitations sont inhérentes à cette approche : notamment, la présence d'unions ou de *casts* entre entiers et pointeurs fait échouer l'analyse.

Le principe de cette technique (associer des types aux valeurs puis restreindre les opérations sur certains types) peut être repris. Par exemple, si on définit un type "numéro de bloc" comme étant un nouvel alias de int, on peut considérer que multiplier deux telles valeurs est une erreur.



## **CONCLUSION**

- 11.1 Limitations
- 11.2 Perspectives



### CODE DU MODULE NOYAU

```
/* from drivers/qpu/drm/radeon/radeon_kms.c */
int radeon_info_ioctl(struct drm_device *dev, void *data, struct drm_file *filp)
        struct radeon_device *rdev = dev->dev_private;
        struct drm_radeon_info *info;
        struct radeon_mode_info *minfo = &rdev->mode_info;
        uint32_t *value_ptr;
        uint32_t value;
        struct drm_crtc *crtc;
        int i, found;
        info = data;
        value_ptr = (uint32_t *)((unsigned long)info->value);
        value = *value_ptr;
        switch (info->request) {
        case RADEON_INFO_DEVICE_ID:
                value = dev->pci_device;
                break;
        case RADEON_INFO_NUM_GB_PIPES:
                value = rdev->num_gb_pipes;
                break;
        case RADEON_INFO_NUM_Z_PIPES:
                value = rdev->num_z_pipes;
                break;
        case RADEON_INFO_ACCEL_WORKING:
                /* xf86-video-ati 6.13.0 relies on this being false for evergreen */
                if ((rdev->family >= CHIP_CEDAR) && (rdev->family <= CHIP_HEMLOCK))</pre>
                        value = false;
                else
                        value = rdev->accel_working;
                break:
        case RADEON_INFO_CRTC_FROM_ID:
```

71

```
for (i = 0, found = 0; i < rdev->num_crtc; i++) {
                crtc = (struct drm_crtc *)minfo->crtcs[i];
                if (crtc && crtc->base.id == value) {
                        struct radeon_crtc *radeon_crtc = to_radeon_crtc(crtc);
                        value = radeon_crtc->crtc_id;
                        found = 1;
                        break;
                }
        }
        if (!found) {
                DRM_DEBUG_KMS("unknown crtc id %d\n", value);
                return -EINVAL;
        }
        break;
case RADEON_INFO_ACCEL_WORKING2:
        value = rdev->accel_working;
        break;
case RADEON_INFO_TILING_CONFIG:
        if (rdev->family >= CHIP_CEDAR)
                value = rdev->config.evergreen.tile_config;
        else if (rdev->family >= CHIP_RV770)
                value = rdev->config.rv770.tile_config;
        else if (rdev->family >= CHIP_R600)
                value = rdev->config.r600.tile_config;
        else {
                DRM_DEBUG_KMS("tiling config is r6xx+ only!\n");
                return -EINVAL;
case RADEON_INFO_WANT_HYPERZ:
        mutex_lock(&dev->struct_mutex);
        if (rdev->hyperz_filp)
                value = 0;
        else {
                rdev->hyperz_filp = filp;
                value = 1;
        }
        mutex_unlock(&dev->struct_mutex);
        break;
default:
        DRM_DEBUG_KMS("Invalid request %d\n", info->request);
        return -EINVAL;
}
if (DRM_COPY_TO_USER(value_ptr, &value, sizeof(uint32_t))) {
        DRM_ERROR("copy_to_user\n");
        return -EFAULT;
}
return 0;
```

```
}
/* from drivers/qpu/drm/radeon/radeon_kms.c */
struct drm_ioctl_desc radeon_ioctls_kms[] = {
        /* KMS */
        DRM_IOCTL_DEF(DRM_RADEON_INFO, radeon_info_ioctl, DRM_AUTH|DRM_UNLOCKED)
};
/* from drivers/gpu/drm/radeon/radeon_drv.c */
static struct drm_driver kms_driver = {
        .driver_features =
            DRIVER_USE_AGP | DRIVER_USE_MTRR | DRIVER_PCI_DMA | DRIVER_SG |
            DRIVER_HAVE_IRQ | DRIVER_HAVE_DMA | DRIVER_IRQ_SHARED | DRIVER_GEM,
        .dev_priv_size = 0,
        .ioctls = radeon_ioctls_kms,
        .name = "radeon",
        .desc = "ATI Radeon",
        .date = "20080528",
        .major = 2,
        .minor = 6,
        .patchlevel = 0,
};
/* from drivers/gpu/drm/drm_drv.c */
int drm_init(struct drm_driver *driver)
{
        DRM_DEBUG("\n");
        INIT_LIST_HEAD(&driver->device_list);
        if (driver->driver_features & DRIVER_USE_PLATFORM_DEVICE)
                return drm_platform_init(driver);
        else
                return drm_pci_init(driver);
}
```

## TODO LIST

À affiner ou supprimer	6
Mettre des vrais nombres plutôt que du symbolique	8
Faire cette figure	10
Redite qui n'apporte pas plus d'explication	10
clarifier encore tout ça	11
Historique + citer le papier de Milner sur le polymorphisme	21
héritage,sous-typage,classe,méthode,héritage multiple,late binding,Liskov	22
introduire l'inférence plus haut	22
lire coccinelle09	25
lister les applications	25
Hoare	25
et Perl?	25
Fonctions	29
Ajouter l'arithmétique des pointeurs + types	29
expliquer pourquoi un while expr ne suffit pas	29
Il faut une opération genre fromBytes	32
Pile d'appels	32
fcall	34
definir $\sigma \vdash fe \Rightarrow f \ldots \ldots \ldots \ldots \ldots \ldots \ldots$	34
accès à un élément d'un type composite	41
Vérifier qu'il n'y a pas de problème entre polymorphisme et mutabilité	42
Notation vecteur	42
Mettre à jour la figure	57
occurs check peut etre?	62
C'est faux	62

## TABLE DES FIGURES

2.1	Cadres de pile	8
2.2	Les différents rings	10
2.3	Implantation de la mémoire virtuelle	10
2.4	Mécanisme de mémoire virtuelle	11
2.5	Espace d'adressage d'un processus	11
2.6	Appel de gettimeofday	14
2.7	Zones mémoire	14
2.8	Implantation de l'appel système gettimeofday	15
3.1	Session Python présentant le typage dynamique	18
3.2	Fonction Python non typable statiquement	19
3.3	Transtypage en Java	20
3.4	Les différents types de polymorphisme	21
3.5	Fonction de concaténation de listes en OCaml	22
3.6	Cas d'ambigüité avec de la surcharge ad-hoc	22
5.1	Syntaxe d'un langage impératif	30
9.1	Décomposition d'un compilateur : front-ends, middle-end, back-ends	55
9.2	Compilation depuis Newspeak	57
9.3	Lambda calcul simplement typé avec entiers, flottants et couples	59
9.4	Arbre d'inférence : règles à utiliser	60
9.5	Arbre d'inférence complet	61
9.6	Unification par partage	62
10 1	Bug freedesktop org #29340	66

## RÉFÉRENCES WEB

- [ 1] The Objective Caml system, documentation and user's manual release 3.12 http://caml.inria.fr/pub/docs/manual-ocaml/
- [�²] Haskell Programming Language Official Website http://www.haskell.org/
- [�³] Python Programming Language Official Website http://www.python.org/
- [�5] Sparse a Semantic Parser for C https://sparse.wiki.kernel.org/index.php/Main\_Page
- [♠7] The C - language http://www.cminusminus.org/
- [ Penjili project http://www.penjili.org/

- [AB07] Andrew W. Appel and Sandrine Blazy. Separation logic for small-step Cminor (extended version). Research report 6138, INRIA, 2007. 29 pages. 56
- [BBC<sup>+</sup>10] Al Bessey, Ken Block, Ben Chelf, Andy Chou, Bryan Fulton, Seth Hallem, Charles Henri-Gros, Asya Kamsky, Scott McPeak, and Dawson Engler. A few billion lines of code later: using static analysis to find bugs in the real world. *Commun. ACM*, 53(2):66–75, February 2010. 25
- [BC05] Daniel P. Bovet and Marco Cesati. *Understanding the Linux Kernel, Third Edition*. O'Reilly Media, third edition edition, November 2005. 10
- [BDH+09] Julien Brunel, Damien Doligez, René Rydhof Hansen, Julia L. Lawall, and Gilles Muller. A foundation for flow-based program matching using temporal logic and model checking. In The 36th Annual ACM SIGPLAN SIGACT Symposium on Principles of Programming Languages, pages 114–126, Savannah, GA, USA, January 2009. 25
- [BDL06] Sandrine Blazy, Zaynah Dargaye, and Xavier Leroy. Formal verification of a C compiler front-end. In FM 2006: Int. Symp. on Formal Methods, volume 4085 of Lecture Notes in Computer Science, pages 460–475. Springer, 2006. 56
- [CC77] Patrick Cousot and Radhia Cousot. Abstract interpretation: a unified lattice model for static analysis of programs by construction or approximation of fixpoints. In POPL '77: Proceedings of the 4th ACM SIGACT-SIGPLAN symposium on Principles of Programming Languages, pages 238–252, New York, NY, USA, 1977. ACM. 25
- [CC92] P. Cousot and R. Cousot. Abstract interpretation and application to logic programs. Journal of Logic Programming, 13(2-3):103-179, 1992. (The editor of Journal of Logic Programming has mistakenly published the unreadable galley proof. For a correct version of this paper, see http://www.di.ens.fr/~cousot.). 25
- [CCF<sup>+</sup>05] Patrick Cousot, Radhia Cousot, Jérôme Feret, Laurent Mauborgne, Antoine Miné, David Monniaux, and Xavier Rival. The ASTREÉ analyzer. In Shmuel Sagiv, editor, ESOP, volume 3444 of Lecture Notes in Computer Science, pages 21–30. Springer, 2005. 26
- [CCF<sup>+</sup>09] Patrick Cousot, Radhia Cousot, Jérôme Feret, Laurent Mauborgne, Antoine Miné, and Xavier Rival. Why does astrée scale up? Formal Methods in System Design, 35(3):229–264, 2009. 25
- [CMP03] Emmanuel Chailloux, Pascal Manoury, and Bruno Pagano. *Développement d'applications avec Objective CAML*. O'Reilly, 2003. 17
- [CMP10] Dumitru Ceară, Laurent Mounier, and Marie-Laure Potet. Taint dependency sequences: A characterization of insecure execution paths based on input-sensitive cause sequences. In *ICST Workshops*, 2010. 26

[DRS00] Nurit Dor, Michael Rodeh, and Mooly Sagiv. CSSV: Towards a realistic tool for statically detecting all buffer overflows in C, 2000. 25

- [EH94] Ana Erosa and Laurie J. Hendren. Taming control flow: A structured approach to eliminating goto statements. In *In Proceedings of 1994 IEEE International Conference on Computer Languages*, pages 229–240. IEEE Computer Society Press, 1994.
- [FFA99] Jeffrey S. Foster, Manuel Fähndrich, and Alexander Aiken. A theory of type qualifiers. In *Programming language design and implementation*, PLDI '99, pages 192–203, 1999. 25, 67
- [FJKA06] Jeffrey S. Foster, Robert Johnson, John Kodumal, and Alex Aiken. Flow-insensitive type qualifiers. *ACM Trans. Program. Lang. Syst.*, 28:1035–1087, November 2006. 25
- [FTA02] Jeffrey S. Foster, Tachio Terauchi, and Alex Aiken. Flow-sensitive type qualifiers. In *PLDI '02 : Proceedings of the ACM SIGPLAN 2002 Conference on Programming language design and implementation*, volume 37, pages 1–12, New York, NY, USA, May 2002. ACM Press. 25
- [Gor04] Mel Gorman. *Understanding the Linux Virtual Memory Manager*. Prentice Hall PTR, Upper Saddle River, NJ, USA, 2004. 10
- [Gra92] Philippe Granger. Improving the results of static analyses programs by local decreasing iteration. In *Proceedings of the 12th Conference on Foundations of Software Technology and Theoretical Computer Science*, pages 68–79, London, UK, UK, 1992. Springer-Verlag. 26
- [Har88] Norm Hardy. The confused deputy (or why capabilities might have been invented). *ACM Operating Systems Review*, 22(4):36–38, October 1988. 15, 65
- [HL08] Charles Hymans and Olivier Levillain. Newspeak, Doubleplussimple Minilang for Goodthinkful Static Analysis of C. Technical Note 2008-IW-SE-00010-1, EADS IW/SE, 2008. 56, 58, 66
- [Int] Intel Corporation. Intel® 64 and IA-32 Architectures Software Developer's Manual. 6, 12
- [ISO99] ISO. The ANSI C standard (C99). Technical Report WG14 N1124, ISO/IEC, 1999. 17, 37, 47, 55
- [JW04] Robert Johnson and David Wagner. Finding user/kernel pointer bugs with type inference. In *USENIX Security Symposium*, pages 119–134, 2004. 25
- [KcS07] Oleg Kiselyov and Chung chieh Shan. Lightweight static capabilities. *Electr. Notes Theor. Comput. Sci.*, 174(7):79–104, 2007. 25
- [Ker81] Brian W. Kernighan. Why Pascal is not my favorite programming language. Technical report, AT&T Bell Laboratories, April 1981. 22
- [KR88] Brian W. Kernighan and Dennis M. Ritchie. *The C Programming Language Second Edition*. Prentice-Hall, Inc., 1988. 17, 55

[LA04] Chris Lattner and Vikram Adve. LLVM: A Compilation Framework for Lifelong Program Analysis & Transformation. In *Proceedings of the 2004 International Symposium on Code Generation and Optimization (CGO'04)*, Palo Alto, California, Mar 2004. 56

- [LZ06] Peng Li and Steve Zdancewic. Encoding information flow in Haskell. In *Proceedings of the 19th IEEE Workshop on Computer Security Foundations (CSFW '06)*, Washington, DC, USA, 2006. IEEE Computer Society. 25
- [Mau04] Laurent Mauborgne. ASTRÉE: Verification of absence of run-time error. In René Jacquart, editor, *Building the information Society (18th IFIP World Computer Congress)*, pages 384–392. The International Federation for Information Processing, Kluwer Academic Publishers, Aug 2004. 26
- [Mer03] J. Merrill. GENERIC and GIMPLE: a new tree representation for entire functions. In GCC developers summit 2003, pages 171–180, 2003. 56
- [Mil78] Robin Milner. A theory of type polymorphism in programming. *Journal of Computer* and System Sciences, 17(3):348–375, December 1978. 21
- [NMRW02] George C. Necula, Scott McPeak, Shree Prakash Rahul, and Westley Weimer. Cil: Intermediate language and tools for analysis and transformation of c programs. In Proceedings of the 11th International Conference on Compiler Construction, CC '02, pages 213–228, London, UK, UK, 2002. Springer-Verlag. 56
- [OGS08] Bryan O'Sullivan, John Goerzen, and Don Stewart. *Real World Haskell*. O'Reilly Media, Inc., 1st edition, 2008. 17
- [One96] Aleph One. Smashing the stack for fun and profit. *Phrack*, 1996. 6, 48
- [Pie02] Benjamin C. Pierce. Types and Programming Languages. MIT Press, 2002. 19, 25
- [PJ03] Simon Peyton Jones, editor. *Haskell 98 Language and Libraries The Revised Report*. Cambridge University Press, Cambridge, England, 2003. 17
- [PJNO97] Simon L. Peyton Jones, Thomas Nordin, and Dino Oliva. C-: A portable assembly language. In Chris Clack, Kevin Hammond, and Antony J. T. Davie, editors, *Implementation of Functional Languages*, volume 1467 of *Lecture Notes in Computer Science*, pages 1–19. Springer, 1997. 56
- [PTS+11] Nicolas Palix, Gaël Thomas, Suman Saha, Christophe Calvès, Julia Lawall, and Gilles Muller. Faults in Linux: Ten years later. In Sixteenth International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS 2011), Newport Beach, CA, USA, March 2011. 25
- [SAB10] Edward J. Schwartz, Thanassis Avgerinos, and David Brumley. All you ever wanted to know about dynamic taint analysis and forward symbolic execution (but might have been afraid to ask). In *Proceedings of the IEEE Symposium on Security and Privacy*, 2010. 25
- [SM03] Andrei Sabelfeld and Andrew C. Myers. Language-based information-flow security. IEEE Journal on Selected Areas in Communications, 21:2003, 2003. 26
- [Spe05] Brad Spengler. grsecurity 2.1.0 and kernel vulnerabilities. *Linux Weekly News*, 2005. 25

[Sta11] Basile Starynkevitch. Melt - a translated domain specific language embedded in the gcc compiler. In Olivier Danvy and Chung chieh Shan, editors, *DSL*, volume 66 of *EPTCS*, pages 118–142, 2011. 56

- [STFW01] Umesh Shankar, Kunal Talwar, Jeffrey S. Foster, and David Wagner. Detecting format string vulnerabilities with type qualifiers. In SSYM'01: Proceedings of the 10th conference on USENIX Security Symposium, page 16, Berkeley, CA, USA, 2001. USENIX Association. 25
- [SY86] R E Strom and S Yemini. Typestate: A programming language concept for enhancing software reliability. *IEEE Trans. Softw. Eng.*, 12(1):157–171, January 1986. 48
- [Tan07] Andrew S. Tanenbaum. *Modern Operating Systems*. Prentice Hall Press, Upper Saddle River, NJ, USA, 3rd edition, 2007. 5
- [VB04] Arnaud Venet and Guillaume Brat. Precise and efficient static array bound checking for large embedded c programs. In *Proceedings of the ACM SIGPLAN 2004 conference on Programming language design and implementation*, PLDI '04, pages 231–242, New York, NY, USA, 2004. ACM. 26
- [Wal00] Larry Wall. *Programming Perl*. O'Reilly & Associates, Inc., Sebastopol, CA, USA, 3rd edition, 2000. 17